



Université Paris 1 Panthéon-Sorbonne
École de Management de la Sorbonne
Master 2 Finance de Marché et Gestion des Risques

Mémoire de recherche

Apprentissage automatique et prévision des rendements boursiers

Présenté par :
Alessio Gino Nocera

Sous la direction de :
Constantin Mellios
Mohamed El Fakir

Année académique 2025/2026

Remerciements

Je tiens à remercier en premier lieu mes directeurs de mémoire, Mohamed El Fakir et Constantin Mellios, pour leur disponibilité, leurs conseils et le temps qu'ils ont consacré à encadrer ce travail. Leurs remarques m'ont permis de préciser mes choix méthodologiques et d'améliorer sensiblement la qualité de ce mémoire.

Je remercie également l'ensemble du corps enseignant du Master 2 Finance de Marché et Gestion des Risques de l'Université Paris 1 Panthéon-Sorbonne, dont les enseignements m'ont donné les bases nécessaires pour mener ce travail de recherche.

Enfin, je remercie mes proches pour leur soutien tout au long de cette année.

Résumé

Ce mémoire évalue quatre modèles de prévision du rendement excédentaire mensuel des actions américaines : une régression linéaire, un Elastic Net, une forêt aléatoire et un modèle de gradient boosting. Les quatre sont entraînés sur le même jeu de données d'entreprise de 2 615 807 observations titre-mois, soit 27 556 entreprises entre 1980 et 2021. L'évaluation repose sur douze fenêtres glissantes dont les blocs de test couvrent 144 mois de 2010 à 2021. La performance est mesurée de deux façons différentes, par le R^2 hors échantillon et par les mesures de portefeuilles triés par décile. Les quatre modèles obtiennent un R^2 de test positif, de 0,27 % à 0,49 %, les deux modèles à arbres devançant les deux modèles linéaires. Les portefeuilles long-short dégagent tous un rendement moyen significatif, avec des ratios de Sharpe de 0,766 à 1,220, mais le modèle le moins précis produit le meilleur portefeuille. Le momentum et la croissance de l'actif ressortent comme les signaux les plus robustes. L'ajout des prédicteurs macroéconomiques agrégés dégrade les quatre modèles, alors qu'un horizon de prévision de douze mois améliore le classement des titres sans se traduire par un meilleur portefeuille. Le pouvoir prédictif décroît avec la capitalisation et les alphas, de 9,37 % à 14,02 % en brut, ne survivent aux coûts de mise en œuvre que pour la forêt aléatoire en pondération par capitalisation.

Mots-clés : apprentissage automatique, *asset pricing* empirique, coupe transversale des rendements, prévision hors échantillon, R^2 hors échantillon, forêt aléatoire, gradient boosting, Elastic Net, portefeuilles triés par décile, ratio de Sharpe, coûts de transaction.

Table des matières

Remerciements	1
Résumé	2
1 Introduction	6
2 Revue de littérature	8
2.1 Modèle factoriel	8
2.1.1 Les modèles à facteurs et leur portée	8
2.1.2 La régularisation	8
2.2 L'apprentissage automatique dans la coupe transversale des rendements . .	9
2.2.1 Apport de Gu, Kelly et Xiu	9
2.2.2 Régressions pénalisées, Arbres, forêts aléatoires et <i>gradient boosting</i> .	9
2.2.3 Réseaux de neurones	10
2.2.4 Extensions et sensibilité des résultats	10
2.3 Variables et univers d'investissement	10
2.4 Portefeuille	11
2.4.1 Portefeuilles triés sur les prévisions	11
2.4.2 Coûts de transaction et stabilité temporelle	12
2.5 Évaluation hors échantillon	12
3 Données	13
3.1 Caractéristiques d'entreprise	13
3.2 Prédicteurs macroéconomiques	13
3.3 Échantillon d'estimation	14
3.3.1 Nettoyages	14
3.3.2 Période retenue et sélection des caractéristiques	14
3.3.3 Fusion des trois sources et définition de la variable expliquée	15
3.3.4 Filtres d'univers investissable	15
3.3.5 Imputation des valeurs manquantes	16
3.3.6 Winsorisation et transformation en rangs	16
4 Cadre méthodologique	17
4.1 Formalisation du problème de prévision	17
4.2 Sélection d'hyperparamètres	18
4.2.1 Découpage temporel	18
4.2.2 Schéma retenu	18

4.2.3	Fenêtres extensives et fenêtres glissantes	19
4.2.4	Agrégation des prévisions et mesure de précision	20
4.3	Modèles estimés	21
4.3.1	La régression linéaire	21
4.3.2	L'Elastic Net	21
4.3.3	La forêt aléatoire	22
4.3.4	Le <i>gradient boosting</i>	24
4.3.5	Mesures d'importance des variables	25
4.4	Construction de portefeuille	26
4.4.1	Portefeuilles triés par décile	26
4.4.2	Mesures de performance	27
4.4.3	Constructions alternatives	27
4.5	Combiner les modèles plutôt que choisir	28
4.6	Analyse par capitalisation	28
4.7	Horizon de prévision de douze mois	29
4.7.1	Définition de la cible	29
4.7.2	Embargo aux frontières des blocs	29
4.7.3	Titres radiés	30
4.7.4	Chevauchement des observations	30
4.7.5	Constructions de portefeuille	30
4.8	Alpha et coûts	31
4.8.1	Alpha contre un modèle à six facteurs	31
4.8.2	Rotation du portefeuille	32
4.8.3	Frais de transaction et coût d'emprunt	32
4.8.4	Coût de seuil de rentabilité	33
5	Résultats	34
5.1	L'échantillon obtenu	34
5.1.1	Fusion des trois sources	34
5.1.2	La variable cible	34
5.1.3	Filtrage de l'univers investissable	35
5.1.4	Imputation, winsorisation et transformation en rang	35
5.2	Précision hors échantillon des modèles	36
5.2.1	Fenêtre glissante ou fenêtre extensive	36
5.2.2	R^2 hors échantillon poolé	36
5.2.3	Évolution fenêtre par fenêtre	37
5.2.4	Hyperparamètres retenus d'une fenêtre à l'autre	38
5.3	Contribution des variables	39
5.3.1	Significativité des caractéristiques	39

5.3.2	Stabilité de la sélection de l'Elastic Net	40
5.3.3	Importance des variables et valeurs de Shapley	41
5.4	Performance des portefeuilles	44
5.4.1	Rendement par décile	44
5.4.2	Mesures de performance	44
5.4.3	Constructions alternatives	46
5.5	Portefeuille combiné	46
5.6	Analyse par segment de capitalisation	47
5.7	Horizon de prévision à douze mois	48
5.7.1	Précision et portefeuilles à douze mois	48
5.7.2	Comparaison des deux horizons	48
5.8	Apport des prédictors macroéconomiques	49
5.9	Alpha factoriel et coûts de mise en œuvre	50
5.9.1	Étude de l'Alpha	50
5.9.2	Rotation et frais	50
6	Discussion	52
6.1	R^2 vs Sharpe	52
6.2	Taille	53
6.3	Pourquoi la moyenne simple l'emporte	53
6.4	Horizon du signal et fréquence de rebalancement	54
6.5	Pourquoi les variables macroéconomiques échouent	54
7	Conclusion	56
A	Annexes	64
A.1	Caractéristiques et prédictors de l'univers candidat	64
A.2	Prédictors macroéconomiques	65
A.3	Significativité des caractéristiques par Fama-MacBeth	67

Chapitre 1

Introduction

Chaque mois, un investisseur construisant un portefeuille d’actions doit classer plusieurs milliers de titres selon le rendement escompté. Longtemps la finance empirique a traité ce problème dans le cadre d’une approche factorielle, du MEDAF de [Sharpe \(1964\)](#) jusqu’au modèle à 5 facteurs de [Fama and French \(2015\)](#). Ces spécifications posent une hypothèse forte : toute information pertinente se résume à un petit nombre d’expositions dont l’effet est constant et additif.

Cette hypothèse est mise à mal par le nombre de signaux désormais documentés. [Green et al. \(2017\)](#) en recensent près d’une centaine pour la seule coupe transversale américaine. Deux difficultés distinctes s’y surajoutent alors. La première porte sur la dimension du jeu de prédicteurs, connue depuis longtemps comme étant prise en charge par les méthodes de régularisation.

La deuxième lacune est celle qui relie la cible aux prédicteurs, relation supposée linéaire, donc suppose un effet marginal constant pour chaque caractéristique, alors que [Freyberger et al. \(2020\)](#) montrent que ces relations sont souvent fortement non linéaires. Le conditionnement de la recherche se libère ainsi en s’attachant à estimer directement cette fonction de prévision dont la forme n’est pas connue a priori, contrairement à la régression pénalisée. [Gu et al. \(2020\)](#) en apportent la démonstration la plus importante en appliquant six approches (régressions pénalisées, méthodes de réduction de dimension, méthodes arborescentes et réseaux de neurones) sur soixante années de données américaines et montrent que les non-linéarités aident à la prédiction des rendements. Ils mettent à disposition une base de caractéristiques d’entreprise qui est reprise dans ce mémoire.

Quatre spécifications sont testées, en fonction d’une souplesse croissante : une régression linéaire par moindres carrés ordinaires, un Elastic Net, une forêt aléatoire et un modèle de *gradient boosting* (LightGBM). Elles prennent les mêmes 30 caractéristiques de l’entreprise, sélectionnées pour être représentatives des grandes classes de signaux documentés, et sont chargées de prédire le rendement excédentaire du mois suivant sur un panel de 2 615 807 observations titre-mois, composé de 27 556 entreprises américaines entre 1980 et 2021. L’univers est restreint chaque mois par les réglementations (capitalisation boursière) et par l’illiquidité d’[Amihud \(2002\)](#), afin de ne conserver que des titres qu’un gérant a réellement la possibilité de conserver. L’évaluation est fondée sur les douze fenêtres glissantes au sein desquelles les blocs de test, assemblés les uns à la suite des autres, couvrent l’ensemble de la période de 144 mois allant de janvier 2010 à décembre 2021.

Le travail s'articule autour de quatre questions posées : les modèles prédisent-ils quelque chose hors échantillon, et la souplesse additionnelle des méthodes non linéaires se traduit-elle par un gain mesurable ? Quelles caractéristiques du signal portent ce signal, et lesquelles résistent à la variation d'une famille complète de modèles ? Quelle est la valeur du signal une fois transposée dans un portefeuille, et sa valeur est-elle dépendante des paramètres de construction ? Enfin, vers quel segment de marché s'oriente-t-il ? Plusieurs extensions complètent ce dispositif. Deux modifient la spécification et exigent une ré-estimation, l'ajout des prédicteurs macroéconomiques agrégés de [Welch and Goyal \(2008\)](#) et le passage à un horizon de prévision de douze mois. Les autres réutilisent les mêmes prévisions, la combinaison des quatre modèles au lieu du choix de l'un d'eux, l'alpha des portefeuilles contre un modèle à six facteurs et leur performance nette de frais de transaction et de coût d'emprunt.

La performance est mesurée de deux façons indépendantes tout au long du mémoire : le R^2 hors échantillon portant sur le niveau des rendements prévus, et les mesures de portefeuille sur leur rang, seul élément propre à déterminer la constitution des déciles. Rien ne dit que ces deux critères classifient les modèles de la même façon, or les résultats attestent qu'ils ne le font pas.

Le chapitre [2](#) inscrit le travail dans la littérature, qu'il s'agisse de modèles à facteurs jusqu'aux travaux qui interrogent la robustesse des résultats élaborés via apprentissage automatique. Le chapitre [3](#) constitue la base utilisée, les prédicteurs retenus et la construction de l'échantillon d'estimation. Le chapitre méthodologique suivant formalise le problème de prévision, le protocole d'évaluation par fenêtres glissantes et détaille les quatre modèles et la méthode de construction des portefeuilles. Le chapitre [5](#) présente l'ensemble des résultats. Le chapitre [6](#) revient sur le constat qui les traverse, la dissociation entre la précision statistique et la performance de portefeuille, et en examine les causes. Le chapitre [7](#) conclut.

Chapitre 2

Revue de littérature

2.1 Modèle factoriel

2.1.1 Les modèles à facteurs et leur portée

La recherche empirique en *asset pricing* a commencé par se concentrer sur des modèles dans lesquels les rendements espérés sont expliqués par un petit nombre de facteurs de risque. Le MEDAF de [Sharpe \(1964\)](#) a été le point de départ de cette approche. Les travaux de [Fama and French \(1993\)](#) ont ensuite élargi ce cadre en introduisant les facteurs de taille et de valeur, avant que [Carhart \(1997\)](#) n'ajoute le *momentum* et que [Fama and French \(2015\)](#) ne propose un modèle à cinq facteurs intégrant également la profitabilité et l'investissement.

Une spécification avec cinq facteurs postule que la totalité de l'information pertinente sur la coupe des rendements transversaux s'exprime par seulement cinq expositions qui sont censées s'additionner. Or le nombre de caractéristiques susceptibles d'expliquer la coupe transversale des rendements a beaucoup augmenté. [Green et al. \(2017\)](#) montrent qu'une minorité de ces signaux apporte une information indépendante, et [Harvey et al. \(2016\)](#) mettent en évidence le problème du *factor zoo* (introduit par [Cochrane \(2011\)](#)), où la multiplication des tests empiriques fait émerger de faux facteurs significatifs.

2.1.2 La régularisation

Les méthodes de régularisation ont été la première réponse à ce problème. La régression Ridge ([Hoerl and Kennard, 1970](#)) réduit l'amplitude des coefficients, le LASSO ([Tibshirani, 1996](#)) en annule une partie et opère ainsi une sélection de variables, et l'Elastic Net ([Zou and Hastie, 2005](#)) combine les deux pénalités, ce qui le rend utile lorsque les caractéristiques sont fortement corrélées entre elles.

Ces méthodes stabilisent l'estimation en grande dimension, mais laissent intacte la forme fonctionnelle

$$r_{i,t+1} = \boldsymbol{\beta}^\top \mathbf{z}_{i,t} + \varepsilon_{i,t+1}, \quad (2.1)$$

où $r_{i,t+1}$ est le rendement futur de l'action i et $\mathbf{z}_{i,t}$ le vecteur de caractéristiques observables en t . L'effet marginal de chaque variable y est constant, alors que [Freyberger et al. \(2020\)](#) montrent que ces relations sont souvent fortement non linéaires. Les méthodes

d'apprentissage lèvent cette contrainte en estimant directement

$$r_{i,t+1} = g(\mathbf{z}_{i,t}) + \varepsilon_{i,t+1}, \quad (2.2)$$

où la fonction $g(\cdot)$ peut intégrer des seuils et des interactions entre caractéristiques.

2.2 L'apprentissage automatique dans la coupe transversale des rendements

2.2.1 Apport de Gu, Kelly et Xiu

L'article de [Gu et al. \(2020\)](#) est important dans ce domaine. Les auteurs comparent, sur un vaste panel d'actions américaines couvrant la période 1957–2016, plusieurs familles de modèles : régressions linéaires pénalisées, méthodes de réduction de dimension, arbres de décision, forêts aléatoires, *gradient boosting* et réseaux de neurones. Leur base de données contient 94 caractéristiques d'entreprises, ainsi que des variables macroéconomiques et des interactions entre signaux individuels et l'état du marché.

Leur principal résultat est que les méthodes non linéaires donnent généralement de meilleurs résultats que les régressions linéaires en hors échantillon. Même si les gains en termes de R^2 mensuel sont faibles, ce qui est habituel pour la prédiction des rendements individuels, ils deviennent importants lorsque les prévisions sont utilisées pour construire des portefeuilles. Les auteurs montrent également que quelques familles de variables, notamment le momentum, la liquidité, la volatilité et certaines caractéristiques fondamentales, jouent un rôle récurrent dans la prédiction.

2.2.2 Régressions pénalisées, Arbres, forêts aléatoires et *gradient boosting*

Le LASSO, la régression Ridge et l'Elastic Net sont toujours des méthodes très utiles dans les travaux de *machine learning* appliqués à la finance. Ils sont rapides à estimer et relativement faciles à interpréter. Ils fournissent également une base de comparaison utile pour déterminer si la complexité supplémentaire d'un modèle non linéaire apporte réellement de l'information. [Chun et al. \(2024\)](#) montrent par exemple que l'Elastic Net peut améliorer la prévision des rendements et la construction de portefeuilles sur les marchés américain et coréen. Cependant, leur principale limite est qu'ils capturent difficilement les interactions et les effets de seuil sans création explicite de nouvelles variables.

Les méthodes arborescentes lèvent cette contrainte. La forêt aléatoire et le *gradient boosting* corrigent l'instabilité d'un arbre isolé par deux stratégies opposées, décrites aux sections [4.3.3](#) et [4.3.4](#). Le constat empirique est celui qui importe ici. [Gu et al. \(2020\)](#)

placent ces deux familles parmi les modèles qui combinent le mieux précision hors échantillon et robustesse sur le marché américain, et [Fieberg et al. \(2023\)](#) obtiennent une hiérarchie comparable sur données européennes.

2.2.3 Réseaux de neurones

En théorie, un réseau assez riche peut approcher une très large classe de fonctions ([Hornik et al., 1989](#)). Dans l'*asset pricing*, leur intérêt réside dans leur capacité à apprendre à la fois des non-linéarités et des interactions complexes. [Gu et al. \(2020\)](#) montrent que certaines architectures profondes sont parmi les meilleures en termes de précision hors échantillon.

Ces modèles ont toutefois un coût computationnel très élevé. Pour les mettre en œuvre, il faut optimiser une grande grille d'hyperparamètres qui doit être réévaluée à chaque fenêtre d'estimation, et agréger plusieurs initialisations aléatoires pour stabiliser les résultats. En raison des limites de temps et de ressources informatiques inhérentes à ce travail, les réseaux de neurones ne sont pas examinés dans le présent mémoire.

2.2.4 Extensions et sensibilité des résultats

La hiérarchie entre modèles varie d'une étude à l'autre selon le marché, la période et la construction du protocole hors échantillon, ce qui suggère qu'aucun algorithme n'est universellement supérieur et que la qualité du dispositif empirique compte autant que la sophistication du modèle ([Fieberg et al., 2023](#); [Wolff and Neugebauer, 2019](#)). [Avramov et al. \(2023\)](#) vont plus loin en montrant qu'une part substantielle de la performance attribuée à ces méthodes se concentre sur les titres les plus difficiles à arbitrer, puis s'érode lorsque des restrictions réalistes sont imposées à l'univers ou à la mise en œuvre. Ce résultat motive deux des analyses menées ici, celles par segment de capitalisation et celle sur les constructions alternatives de portefeuille.

2.3 Variables et univers d'investissement

La performance d'un modèle dépend autant des variables qui lui sont fournies et de l'univers sur lequel il est estimé que de l'algorithme lui-même.

L'inventaire le plus utilisé est celui de [Green et al. \(2017\)](#), qui rassemble une centaine de signaux documentés dans la littérature sur la coupe transversale des rendements américains. La littérature le classe en peu de familles, d'après la source d'information à laquelle chaque signal est dû : les tendances de prix, dont le *momentum* de [Jegadeesh and Titman \(1993\)](#) reste le représentant le plus robuste ; les ratios de valorisation, qui rapportent le prix de marché à une grandeur comptable ([Rosenberg et al., 1985](#); [Fama and French, 1993](#)) ; les mesures de rentabilité et de politique d'investissement, dont [Fama and French](#)

(2015) ont fait des facteurs à part entière ; la qualité des résultats comptables, mise en évidence par les travaux sur les *accruals* (Sloan, 1996) ; et les variables de taille, de liquidité et de risque (Amihud, 2002; Ang et al., 2006), qui renseignent sur les conditions auxquelles son titre s'échange.

Ce découpage a une conséquence pratique. Les signaux d'une même famille sont fortement corrélés entre eux, si bien que les retenir tous apporte peu au-delà des premiers. On conserve donc l'essentiel de la diversité d'information en choisissant un sous-ensemble qui couvre chaque famille, tout en réduisant nettement la dimension.

Enfin la prime de risque exigée sur les actions varie avec le cycle, et Chen et al. (1986) ont établi tôt que des variables d'état macroéconomiques sont rémunérées dans la coupe transversale.

2.4 Portefeuille

2.4.1 Portefeuilles triés sur les prévisions

Le tri en portefeuilles est l'instrument de travail de l'*asset pricing* empirique. La procédure classe les titres selon une caractéristique, les répartit en quantiles, et lit l'existence d'une prime dans l'écart de rendement entre les groupes extrêmes : c'est ainsi que Fama and French (1993) construisent leurs facteurs de taille et de valeur, et que Jegadeesh and Titman (1993) mettent en évidence le *momentum* sur des déciles. Son intérêt tient à son caractère non paramétrique. Aucune forme fonctionnelle n'est imposée à la relation entre le signal et le rendement, si bien qu'une relation non monotone ou concentrée sur une partie de la distribution reste visible dans le profil des quantiles, là où une régression linéaire la résumerait par une pente unique.

Les recherches en apprentissage automatique reprennent cette idée, mais en changeant la variable de tri. Au lieu d'utiliser une caractéristique observable, on utilise le rendement prédit par le modèle, c'est-à-dire un score qui intègre toutes les caractéristiques disponibles. Seule la variable de tri change : le découpage en quantiles, le calcul du rendement de chaque groupe et la lecture de l'écart entre les extrêmes restent identiques. L'écart long-short obtenu par un modèle d'apprentissage est donc une mesure similaire à celle d'une anomalie, et peut être comparée directement aux chiffres trouvés dans la littérature.

Le lien entre la précision statistique et la performance d'un portefeuille n'est pas automatique. Une amélioration du R^2 hors échantillon peut concerner des titres situés au centre de la distribution, ou être trop faible pour modifier la composition des déciles extrêmes. C'est pourquoi les deux critères sont présentés ensemble au chapitre 5.

2.4.2 Coûts de transaction et stabilité temporelle

Les stratégies fondées sur des prévisions mensuelles peuvent entraîner une rotation élevée, en particulier lorsqu’une faible variation de score fait passer une action d’un quantile à l’autre. Les coûts de transaction, la liquidité et l’impact de marché réduisent alors la performance réellement exploitable (Leung et al., 2021; Novy-Marx and Velikov, 2016).

La stabilité temporelle constitue un second test. Wolff and Neugebauer (2019) montrent que la performance relative des modèles arborescents varie selon les sous-périodes. Mekelburg and Strauss (2024) proposent des techniques de regroupement et de winsorisation afin d’améliorer la robustesse des prévisions en grande dimension. Ces travaux rappellent qu’un bon résultat moyen sur plusieurs décennies peut recouvrir des périodes de sous-performance prolongée, ce qui justifie de suivre la performance fenêtre par fenêtre plutôt que sur la seule série agrégée.

2.5 Évaluation hors échantillon

Les séries financières ne sont pas stationnaires, et les relations qui semblent fortes dans l’échantillon d’estimation deviennent souvent plus faibles à l’extérieur. La mesure de référence est le R^2 hors échantillon, calculé sur des observations postérieures à celles qui ont servi à estimer le modèle. Elle s’est imposée à la suite de Welch and Goyal (2008) et Campbell and Thompson (2008), dont les travaux sur la prévisibilité de la prime de risque agrégée l’ont établie comme critère standard.

L’évaluation consiste donc à comparer le modèle à une référence de base. Or, la moyenne historique par titre étant un estimateur trop bruité à ce niveau, la littérature récente lui préfère une prévision constamment nulle (détaillée en section 4.2.4).

Une mesure hors échantillon ne protège de rien si elle a servi à choisir le modèle qui la produit. Selon López de Prado (2018), il existe plusieurs moyens par lesquels des informations futures peuvent être intégrées dans un *backtest* sans être détectées, notamment des observations qui se chevauchent, des transformations calibrées sur l’ensemble de l’échantillon, un univers défini à partir de titres qui survivent, ou la répétition d’essais jusqu’à l’obtention d’un résultat satisfaisant. Le dernier mécanisme est le plus difficile à détecter, puisqu’il ne laisse aucune trace dans le code.

Ces études ne présentent pas une technique spécifique, mais plutôt une exigence, et c’est dans cette optique qu’elles structurent le chapitre suivant. Il est essentiel de séparer strictement les données utilisées pour la sélection et celles utilisées pour tirer des conclusions. De plus, la sélection des hyperparamètres doit être effectuée à l’intérieur de chaque période, plutôt que d’être faite une seule fois pour toutes les périodes. López de Prado (2018) souligne ainsi l’importance de cette séparation pour la validité des résultats.

Chapitre 3

Données

3.1 Caractéristiques d’entreprise

Les caractéristiques d’entreprise proviennent de la base construite par [Gu et al. \(2020\)](#) à partir de CRSP, pour les prix et les rendements mensuels, et de Compustat, pour les données comptables. Elle rassemble 94 caractéristiques dont les définitions reprennent pour l’essentiel celles de [Green et al. \(2017\)](#), avec quelques ajustements destinés à se rapprocher de constructions de référence, la valeur comptable des capitaux propres et la profitabilité opérationnelle suivant par exemple [Fama and French \(2015\)](#). L’échantillon couvre les titres cotés au NYSE, à l’AMEX et au NASDAQ de mars 1957 à décembre 2021, à fréquence mensuelle. Les caractéristiques ne sont toutefois pas toutes mises à jour au même rythme, certaines annuellement, d’autres trimestriellement ou mensuellement, afin de refléter la fréquence de publication réelle de chaque type d’information.

Deux propriétés du fichier importent pour la suite. Une caractéristique n’est utilisable pour prévoir un rendement qu’à partir du moment où elle est effectivement connue des investisseurs, ce qui impose un délai variable selon la source comptable. Les auteurs appliquent un mois pour les caractéristiques mensuelles, quatre mois pour les trimestrielles et six mois pour les annuelles. Cette convention étant déjà intégrée au fichier, aucun décalage supplémentaire n’est appliqué ici. De plus la base est distribuée gratuitement sur le site personnel de Dacheng Xiu sous la forme d’un fichier .csv compressé, accompagné d’un fichier readme qui précise la convention de décalage temporel décrite plus haut.

3.2 Prédicteurs macroéconomiques

Les caractéristiques décrites jusqu’ici sont particulières à chaque entreprise. Deux titres observés le même mois se distinguent par leur *book-to-market* ou leur *momentum* ; le même titre observé en 1990 puis en 2008 ne porte, lui, aucune information sur l’état du marché à ces deux dates. Or la prime de risque attendue sur une action dépend aussi de la conjoncture, et une relation estimée en moyenne sur quarante ans peut recouvrir des régimes très différents. C’est pour cette raison que [Gu et al. \(2020\)](#) complètent leur base d’entreprises par huit séries agrégées, reprises de [Welch and Goyal \(2008\)](#). On fait le même choix, à partir du fichier de données que ces derniers mettent à jour et diffusent publiquement.

Contrairement aux caractéristiques d'entreprise, dont les décalages sont déjà présents dans le fichier mis à disposition par [Gu et al. \(2020\)](#), les lignes de [Welch and Goyal \(2008\)](#) sont datées du mois auquel elles se rapportent. Par mesure de précaution et de réalisme (*data leakage*), je décale donc l'ensemble des huit prédicteurs d'un mois avant la fusion. Maintenant la valeur observée en fin de mois t est rattachée aux observations qui servent à prévoir le rendement du mois $t + 1$. Le taux sans risque, lui, n'est pas décalé, puisqu'il est soustrait au rendement du mois auquel il correspond, la cible à prédire étant le rendement excédentaire.

De plus les huit séries sont exprimées dans des unités hétérogènes, allant du logarithme d'un ratio au taux annuel en pourcentage, et une pénalité de norme comme celle de l'Elastic Net n'est pas invariante à l'échelle des variables. Elles sont donc centrées et réduites fenêtre par fenêtre pour éviter des fuites d'information future.

3.3 Échantillon d'estimation

3.3.1 Nettoyages

Les caractéristiques, les rendements et les séries macroéconomiques sont nettoyés séparément, avant toute fusion.

Du côté des caractéristiques, le fichier est d'abord restreint à la période retenue, et ensuite j'ai réduit le nombre de caractéristiques, ne laissant ainsi que celles que l'on compte inclure dans mes modèles.

Du côté des rendements, la colonne de rendement mensuel n'est pas entièrement numérique, en effet elle contient des lettres qui signalent une absence de cotation ou une situation particulière du titre. Ces codes sont convertis en valeurs manquantes, puis supprimés. Les rendements extrêmes sont conservés tels quels et seulement documentés. À la suite du filtrage sur la capitalisation boursière ainsi que sur la liquidité, une grande partie de ces rendements extrêmes a été écartée.

Du côté des séries macroéconomiques, le traitement est celui décrit à la section [3.2](#).

3.3.2 Période retenue et sélection des caractéristiques

Deux décisions déterminent la taille du jeu de prédicteurs. La première est le point de départ de l'échantillon, fixé à 1980. La base remonte à 1957, mais le taux de valeurs manquantes des caractéristiques est très inégal selon la décennie. Dans les années 50 ce taux s'élevait presque à 80% jusqu'à sa chute dans les années 80 à un peu plus de 30%. Cela est dû à la couverture de Compustat qui s'améliore à mesure qu'on avance dans le temps.

La seconde décision porte sur les caractéristiques elles-mêmes. On part d'un univers

candidat de trente signaux, choisis pour couvrir chaque prédicteur connu de la littérature déjà mentionné en 2.3 tout en gardant un ensemble de taille raisonnable au regard du temps de calcul qu'exigent les modèles arborescents. Chacune de ces variables choisies ont moins de 35% de valeurs manquantes, donc sont toutes conservées pour la suite de la modélisation.

3.3.3 Fusion des trois sources et définition de la variable expliquée

Les caractéristiques et les rendements sont regroupés par jointure interne sur le couple constitué de l'identifiant du titre et du mois. On ne conserve une ligne que si le titre figure dans les deux fichiers pour ce mois-là.

On rattache ensuite par mois les huit prédicteurs macroéconomiques, décalés d'un mois, et le taux sans risque, non décalé. Les quelques lignes sans correspondance macroéconomique sont supprimées.

La variable expliquée est le rendement excédentaire mensuel :

$$r_{i,t+1} = R_{i,t+1} - R_{t+1}^f, \quad (3.1)$$

où $R_{i,t+1}$ est le rendement total du titre i sur le mois $t + 1$, dividendes réinvestis, tel que fourni par CRSP. L'utilisation du rendement excédentaire permet d'isoler la prime liée à la détention d'un actif risqué, ce qui continue d'ailleurs l'un des principaux objets d'étude des modèles de valorisation d'actifs. Aussi comme le taux sans risque est identique pour tous les titres à une date donnée, l'utilisation du rendement excédentaire ne change pas leur classement en coupe transversale. Ce choix facilite enfin l'analyse des portefeuilles menée au chapitre suivant. Leurs rendements étant déjà exprimés en excès du taux sans risque, ils peuvent être directement utilisés pour calculer le ratio de Sharpe.

3.3.4 Filtres d'univers investissable

Hou et al. (2020) répliquent plusieurs centaines d'anomalies documentées et montrent qu'une part importante d'entre elles ne survit ni au retrait des micro-capitalisations, ni au passage d'une pondération égale à une pondération par la capitalisation.

Le panel fusionné contient des titres qu'aucun gérant ne pourrait détenir en pratique. Pour y pallier, on va filtrer l'univers via deux variables du jeu de prédicteurs : la capitalisation boursière (`mvel1`) et la mesure d'illiquidité d'Amihud (2002) (`ill`), toutes deux présentes dans la base de Gu et al. (2020). Elles sont aussi par ailleurs parmi les caractéristiques explicatives utilisées dans les modèles.

Les filtres sont appliqués successivement et mois par mois. Le premier écarte, à chaque date, les titres dont la capitalisation est inférieure au dixième centile de la coupe transversale de ce mois. Le second écarte ensuite les titres dont l'illiquidité dépasse le quatre-

vingt-dixième centile et ceci sur la population déjà coupée de son décile de capitalisation le plus bas. Les lignes pour lesquelles `mvel1` ou `ill` est manquante sont supprimées avant le filtre correspondant, procédure jugée acceptable vu le pourcentage faible de valeurs manquantes de ces variables, 0.01% `mvel1` et 3.14% pour `ill`. Le caractère mensuel du calcul signifie qu’une entreprise peut sortir de l’univers un mois et y revenir le suivant.

3.3.5 Imputation des valeurs manquantes

Une entreprise peut ne pas publier un chiffre une année donnée, ou une variable de marché peut manquer pour un titre peu suivi, ce qui fait qu’il y a des trous dans les données.

Ces valeurs manquantes sont remplacées par la médiane transversale de la caractéristique calculée sur le mois concerné. En effet la médiane est calculée sur la population du mois, ce qui évite le *dataleakage* et elle est insensible aux valeurs extrêmes, contrairement à la moyenne.

3.3.6 Winsorisation et transformation en rangs

Deux transformations sont ensuite appliquées à chaque caractéristique, toujours à l’intérieur de chaque mois.

La winsorisation ramène les valeurs situées au-delà des premier et quatre-vingt-dix-neuvième centiles à ces bornes. La transformation en rangs remplace ensuite chaque valeur par sa position relative dans la coupe transversale du mois, ramenée à l’intervalle $[-1, 1]$:

$$\tilde{c}_{i,t} = 2 \frac{\text{rang}(c_{i,t}) - 1}{N_t - 1} - 1, \quad (3.2)$$

où N_t est le nombre de titres présents au mois t . Le titre le plus bas de la coupe reçoit la valeur -1 , le plus haut la valeur $+1$, et la médiane la valeur 0 .

Mis en lumière par [Freyberger et al. \(2020\)](#), [Gu et al. \(2020\)](#) l’adapte pour projeter les caractéristiques entre -1 et 1 . Utiliser cette méthode a ses avantages : Après le passage en rangs, toutes les variables vivent sur le même intervalle borné, ce qui rend les coefficients d’une régression pénalisée comparables entre eux donc supprime la dépendance de la pénalité à l’unité de mesure. La transformation est également monotone, donc elle préserve l’ordre des titres.

Chapitre 4

Cadre méthodologique

4.1 Formalisation du problème de prévision

Le panel comporte N_t titres au mois t , ce nombre variant d'un mois à l'autre, et T mois au total. À chaque couple (i, t) est associé un vecteur de prédicteurs $\mathbf{z}_{i,t} \in \mathbb{R}^P$, formé des $P = 30$ caractéristiques de l'entreprise i transformées en rangs au mois t ,

$$\mathbf{z}_{i,t} = \tilde{\mathbf{c}}_{i,t}. \quad (4.1)$$

Les huit variables agrégées décrites à la section 3.2 ne font pas partie de cette spécification de référence. Leur apport est évalué séparément à la section 5.8, où elles sont ajoutées au vecteur $\mathbf{z}_{i,t}$.

La grandeur à prévoir est le rendement excédentaire du mois suivant, $r_{i,t+1}$, défini par l'équation (3.1). Le modèle statistique s'écrit

$$r_{i,t+1} = g^*(\mathbf{z}_{i,t}) + \varepsilon_{i,t+1}, \quad \mathbb{E}[\varepsilon_{i,t+1} \mid \mathbf{z}_{i,t}] = 0, \quad (4.2)$$

où g^* est la fonction inconnue à estimer.

Les quatre modèles sont estimés en minimisant l'erreur quadratique sur le bloc d'entraînement $\mathcal{T}^{\text{tr}}$:

$$\hat{g} = \arg \min_{g \in \mathcal{G}} \frac{1}{|\mathcal{T}^{\text{tr}}|} \sum_{(i,t) \in \mathcal{T}^{\text{tr}}} (r_{i,t+1} - g(\mathbf{z}_{i,t}))^2 + \Omega(g), \quad (4.3)$$

où $\mathcal{G}$ est la classe de fonctions propre à chaque modèle et Ω le terme de régularisation qui lui est associé. Ce sont ces deux éléments qui distinguent les quatre modèles les uns des autres : la régression linéaire prend $\mathcal{G}$ linéaire et $\Omega = 0$, l'Elastic Net garde $\mathcal{G}$ linéaire et pénalise la norme des coefficients, les deux modèles arborescents prennent pour $\mathcal{G}$ des sommes de fonctions constantes par morceaux et régularisent par la taille des arbres.

L'équation (4.3) porte sur le niveau des rendements prévus. L'utilisation de cette prédiction est la construction d'un portefeuille trié par décile que au final ne dépend que de l'ordre des titres à l'intérieur de chaque mois. Deux modèles peuvent avoir un R^2 qui diffère et un portefeuille identique si l'unique différence entre les deux est la constante mensuelle des prévisions.

Un modèle peut donc réussir sur un critère et échouer sur l'autre. On le verra prochainement qu'avoir le meilleur R^2 ne signifie pas forcément d'avoir le meilleur portefeuille (selon les métriques choisies). C'est pourquoi la performance est mesurée de deux manières indépendantes dans tout ce qui suit : par le R^2 hors échantillon, défini à la section 4.2.4, et par des mesures de classement et de performance de portefeuille, définies à la section 4.4. Aucune des deux n'est moins importante que l'autre.

4.2 Sélection d'hyperparamètres

4.2.1 Découpage temporel

La validation croisée en K blocs traditionnelle répartit aléatoirement les observations sans respecter leur ordre chronologique. Si on l'applique à un panel d'actions le modèle est alors entraîné sur des données futures pour prédire des rendements passés. La performance mesurée est entachée d'un biais d'anticipation et ne reflète aucune stratégie d'investissement réalisable en temps réel. Bien que [Bergmeir and Benítez \(2012\)](#) rappellent que les dépendances temporelles violent théoriquement l'hypothèse d'observations indépendantes et identiquement distribuées (i.i.d.) de la validation croisée standard, ils montrent qu'elle reste empiriquement robuste pour la sélection de modèles stationnaires et préconisent l'usage d'une validation croisée par blocs. À l'inverse, dans le cadre de la finance quantitative, [López de Prado \(2018\)](#) démontre que le non-respect de ces dépendances et le chevauchement des données entraînent une fuite d'information systématique entre l'entraînement et le test, faisant de la validation croisée classique l'une des principales sources de surapprentissage des *backtests* et de résultats non reproductibles.

De plus les rendements des entreprises d'un même mois partagent des chocs de marché communs, ce qui rend leurs résidus fortement corrélés au sein de chaque période ([Peter-
sen, 2009](#)). Un découpage aléatoire placerait donc une partie des titres d'un mois dans l'échantillon d'entraînement et le reste dans l'échantillon de test, alors même que ces observations sont en grande partie redondantes. La performance mesurée refléterait pour partie cette redondance plutôt qu'une véritable capacité prédictive.

4.2.2 Schéma retenu

La validation progressive (*walk-forward validation*) simule les conditions réelles d'un investisseur en faisant avancer séquentiellement dans le temps une fenêtre d'estimation subdivisée en trois blocs chronologiquement successifs et disjoints :

- un bloc d'**entraînement** $\mathcal{T}_k^{\text{tr}}$, sur lequel les paramètres du modèle sont estimés ;
- un bloc de **validation** $\mathcal{T}_k^{\text{val}}$, immédiatement postérieur, sur lequel les hyperparamètres sont sélectionnés ;

- un bloc de **test** $\mathcal{T}_k^{\text{te}}$, encore postérieur, sur lequel le modèle retenu produit ses prévisions.

Rendue populaire dans la littérature récente d'*asset pricing* par les travaux de [Gu et al. \(2020\)](#), cette approche séquentielle est systématiquement appliquée par les acteurs majeurs du domaine. On la retrouve ainsi sous forme de fenêtres glissantes (*rolling windows*) chez [Wolff and Neugebauer \(2019\)](#) et [Leung et al. \(2021\)](#), ou sous un format de fenêtres extensives (*expanding windows*) chez [Kurucan and Hepşen \(2025\)](#), éliminant tout risque de biais d'anticipation.

Chaque modèle est ré-estimé plusieurs fois, sur une succession de fenêtres qui avancent dans le temps. La fenêtre suivante décale l'ensemble du dispositif vers l'avant : le bloc de test de la fenêtre k devient une période connue, donc utilisable pour l'entraînement ou la validation de la fenêtre $k + 1$.

Les paramètres du découpage sont fixés pour la première fenêtre à dix-huit années d'entraînement, douze années de validation et une de test. Sur la période couverte par le panel, cette configuration produit les 12 fenêtres de la figure 4.1 : la première est entraînée sur 1980–1997, validée sur 1998–2009 et testée sur 2010, et les suivantes décalent l'ensemble d'un an. Les blocs de test mis bout à bout couvrent ainsi les années 2010 à 2021. La période de validation diminue au fil des années avec un plancher de 4 années pour pouvoir inclure les années les plus récentes dans le bloc d'entraînement.




FIGURE 4.1 – Protocole d'évaluation hors échantillon pour fenêtre extensive.

4.2.3 Fenêtres extensives et fenêtres glissantes

Deux façons de faire avancer le bloc d'entraînement sont possibles. En mode extensif, l'entraînement conserve son point de départ initial et s'allonge à chaque fenêtre. Le modèle accumule alors toute l'histoire disponible, ce qui suppose que l'information ancienne reste pertinente pour prédire les rendements récents.

En mode glissant, l'entraînement garde une longueur fixe et oublie ses années les plus anciennes à mesure qu'il avance. Le modèle s'adapte plus vite à un changement de régime mais a un échantillon plus petit et donc de paramètres estimés avec moins de précision.

4.2.4 Agrégation des prévisions et mesure de précision

Les prévisions de test de toutes les fenêtres sont concaténées en une seule série hors échantillon, sur laquelle nous calculons un R^2 unique. Moyenner les R^2 obtenus fenêtre par fenêtre donnerait un résultat différent. Une moyenne simple surpondérerait les fenêtres les plus courtes et les périodes les moins volatiles. L'agrégation préalable des prévisions évite cette distorsion et suit la pratique de [Gu et al. \(2020\)](#) et [Campbell and Thompson \(2008\)](#), une méthodologie également adoptée par [Mekelburg and Strauss \(2024\)](#) et [Wolff and Neugebauer \(2019\)](#) pour évaluer de manière robuste des modèles ré-estimés périodiquement dans un cadre de validation progressive (*walk-forward*).

En reprenant la définition donnée à la section 2.5, la statistique retenue s'écrit, sur l'ensemble $\mathcal{T}^{\text{te}} = \bigcup_k \mathcal{T}_k^{\text{te}}$ des périodes de test :

$$R_{\text{oos}}^2 = 1 - \frac{\sum_{(i,t) \in \mathcal{T}^{\text{te}}} (r_{i,t+1} - \hat{r}_{i,t+1})^2}{\sum_{(i,t) \in \mathcal{T}^{\text{te}}} r_{i,t+1}^2}, \quad (4.4)$$

où $r_{i,t+1}$ est le rendement excédentaire réalisé du titre i et $\hat{r}_{i,t+1}$ la prévision produite par le modèle de la fenêtre à laquelle appartient le mois $t + 1$.

Le dénominateur de l'équation (4.4) compare le modèle à une prévision constamment nulle, et non à la moyenne historique des rendements comme le fait le R^2 usuel. Ce benchmark a été introduit par [Gu et al. \(2020\)](#) pour l'évaluation des rendements d'actions individuelles en coupe transversale, et il est depuis largement repris dans la littérature d'*asset pricing* par apprentissage automatique. Sur un panel d'actions individuelles, la moyenne historique des rendements est un estimateur instable et bruité, qui sous-performe largement une prévision nulle. La retenir comme référence abaisse donc le seuil d'évaluation, et [Gu et al. \(2020\)](#) estiment que le R_{oos}^2 ainsi obtenu dépasse d'environ trois points de pourcentage celui calculé contre une prévision nulle.

La série de prévisions issue de l'équation (4.4) est celle qui alimente la construction des portefeuilles par décile de la section suivante.

Le dénominateur du R^2 hors échantillon de l'équation (4.4) est la somme des carrés des rendements réalisés, c'est-à-dire une quantité liée à la volatilité de l'univers considéré. Comparer le R^2 de deux sous-populations qui ont des volatilités différentes, comme les petites et les grandes capitalisations, n'est pas possible puisque le R^2 de la population la moins volatile sera automatiquement plus élevé que le R^2 de la plus volatile. Le coefficient d'information ne dépend que de l'ordre des titres et est donc comparable d'un sous-univers

à l'autre. C'est pour cette raison qu'il devient la mesure centrale des sections 5.6.

Une mesure, calculée sur les prévisions, est utilisée pour comparer les modèles appliqués à différentes sous-populations : la corrélation de rang de Spearman (Spearman, 1904) entre le classement prévu et le classement réalisé, à l'intérieur de chaque mois,

$$IC_t = \text{corr}(\text{rang}(\hat{r}_{i,t+1}), \text{rang}(r_{i,t+1})). \quad (4.5)$$

4.3 Modèles estimés

Les quatre modèles retenus ont été sélectionnés par flexibilité croissante. La régression linéaire par moindres carrés ordinaires impose une forme fonctionnelle rigide et n'a aucun paramètre à régler. L'Elastic Net garde cette forme linéaire mais peut pénaliser l'amplitude des coefficients. La forêt aléatoire et le *gradient boosting* construisent des approximations constantes par morceaux, capables des relations non linéaires entre prédicteurs.

Les quatre modèles partagent tout le reste : les prédicteurs, les variables expliquées, les fenêtres, les séries hors échantillon en sortie. Le tableau 4.1 récapitule les grilles explorées.

4.3.1 La régression linéaire

Le premier modèle restreint $\mathcal{G}$ aux fonctions linéaires et annule le terme de régularisation :

$$\hat{\beta} = \arg \min_{\beta} \sum_{(i,t) \in \mathcal{T}^{\text{tr}}} (r_{i,t+1} - \beta_0 - \beta^\top \mathbf{z}_{i,t})^2, \quad (4.6)$$

dont la solution est celle des équations normales usuelles. Le modèle est ré-estimé sur le bloc d'entraînement de chaque fenêtre. Il n'a pas d'hyperparamètre donc il n'utilise pas son bloc de validation pour choisir quoi que ce soit.

Sa fonction dans ce mémoire est celle d'une référence. Il fournit la performance qu'on obtient en supposant que chaque caractéristique agit de façon additive, avec un effet marginal constant.

4.3.2 L'Elastic Net

Le deuxième modèle conserve la forme linéaire mais ajoute à l'équation (4.6) une pénalité qui combine celles du LASSO (Tibshirani, 1996) et de la régression Ridge (Hoerl and Kennard, 1970), selon la formulation de Zou and Hastie (2005) :

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{2n} \sum_{(i,t) \in \mathcal{T}^{\text{tr}}} (r_{i,t+1} - \beta_0 - \beta^\top \mathbf{z}_{i,t})^2 + \alpha \rho \|\beta\|_1 + \frac{\alpha(1-\rho)}{2} \|\beta\|_2^2, \quad (4.7)$$

où n est le nombre d'observations d'entraînement, $\alpha \geq 0$ règle l'intensité de la pénalité et $\rho \in [0, 1]$ son équilibre entre les deux normes. Les cas limites sont instructifs : $\alpha \rightarrow 0$

redonne l'équation (4.6), $\rho = 1$ donne le LASSO, $\rho = 0$ la régression Ridge.

Le terme en norme ℓ_1 peut annuler exactement certains coefficients et alors que le terme en norme ℓ_2 ne le fait pas, mais il stabilise l'estimation lorsque des prédicteurs sont fortement corrélés entre eux. Les caractéristiques du panel sont loin d'être orthogonales puisqu'on a sélectionné plusieurs caractéristiques par familles telles que trois horizons de *momentum* ou les quatre ratios de valorisation. Appliqué à notre cas un lasso tendrait à choisir l'un d'entre eux par familles arbitrairement et à annuler les autres, là où la composante ridge elle répartit les poids entre eux.

L'estimation est menée par descente par coordonnées (Friedman et al., 2010), avec un plafond de mille itérations par modèle candidat. La grille explorait cinq valeurs de α réparties logarithmiquement entre 10^{-5} et 10^{-1} , et cinq valeurs de ρ entre 0,1 et 0,9, soit vingt-cinq combinaisons évaluées indépendamment sur chaque fenêtre. Après une première passe les valeurs de α explorées sont restreintes à 10^{-4} et 10^{-3} (10^{-5} jamais sélectionné), en effet une pénalisation de 10^{-2} ou au-delà annule la totalité des coefficients sur une part importante des fenêtres les plus récentes ce qui réduit alors le modèle à sa constante et produit une prévision identique pour tous les titres d'un même mois. Le R_{oos}^2 correspondant n'a donc rien d'alarmant mais un tel modèle ne classe plus rien, les déciles deviennent arbitraires et la richesse cumulée du portefeuille long-short est pratiquement plate.

Les dix combinaisons étant réévaluées à chaque fenêtre, les hyperparamètres choisis changent au fil du temps, et cela entraîne aussi un changement des variables sélectionnées. On relève donc pour chaque prédicteur la fréquence à laquelle son coefficient est non nul sur l'ensemble des fenêtres, ainsi que la cohérence du signe de ce coefficient. Cette lecture reprend l'intuition de la sélection par stabilité de Meinshausen and Bühlmann (2010), selon laquelle la fréquence à laquelle un prédicteur est retenu sous perturbation de l'échantillon renseigne davantage que son coefficient sur un ajustement unique.

4.3.3 La forêt aléatoire

Le troisième modèle abandonne la linéarité. Un arbre de régression (Breiman et al., 1984) découpe l'espace des prédicteurs en régions disjointes $R_1, \dots, R_J$ par une suite de coupures binaires, et prédit dans chaque région la moyenne des rendements d'entraînement qui s'y trouvent :

$$h(\mathbf{z}) = \sum_{j=1}^J \bar{r}_{R_j} \mathbf{1}\{\mathbf{z} \in R_j\}, \quad \bar{r}_{R_j} = \frac{1}{|R_j|} \sum_{(i,t) \in R_j} r_{i,t+1}. \quad (4.8)$$

Chaque coupure est choisie, parmi tous les couples formés d'une variable et d'un seuil, comme celle qui réduit le plus la somme des carrés des écarts à l'intérieur des deux régions qu'elle engendre. Un arbre construit de cette sorte présente nécessairement des effets de

seuil et des interactions : la valeur prédite dépend de la totalité du chemin suivi dans l'arbre, c'est-à-dire de la conjonction de plusieurs conditions.

Pris isolément, un arbre profond est instable parce qu'un petit changement dans l'échantillon d'apprentissage peut faire déplacer une coupure haute et réorganiser tout ce qui se trouve en dessous. Le *bagging* (Breiman, 1996) corrige ce défaut en construisant B arbres sur B échantillons *bootstrap* et en moyennant leurs prévisions. La forêt aléatoire (Breiman, 2001) ajoute une seconde source de randomisation : à chaque nœud, la coupure n'est cherchée que parmi un sous-ensemble tiré au hasard des prédicteurs.

L'intérêt de cette seconde randomisation se lit dans la variance de la moyenne de B prévisions de même variance σ^2 et de corrélation deux à deux ϱ (Hastie et al., 2009) :

$$\text{Var}\left(\frac{1}{B} \sum_{b=1}^B h_b(\mathbf{z})\right) = \varrho \sigma^2 + \frac{1-\varrho}{B} \sigma^2. \quad (4.9)$$

Le second terme s'annule quand B augmente, mais le premier ne dépend pas de B : ajouter des arbres ne sert plus à rien une fois qu'ils sont fortement corrélés entre eux. C'est ce plancher que le tirage de variables à chaque nœud fait baisser. L'argument a une portée directe sur des caractéristiques financières redondantes, où deux arbres construits sur le même échantillon retiendraient sinon les mêmes coupures.

Hyperparamètres. La forêt compte trois cents arbres. Contrairement au nombre d'arbres d'un modèle de *boosting* ce paramètre n'expose à aucun surapprentissage supplémentaire : l'équation (4.9) montre qu'augmenter B ne fait que réduire un terme de variance, au prix d'un temps de calcul proportionnel. Au-delà de quelques centaines d'arbres, le gain devient négligeable.

La régularisation passe par trois autres paramètres. La profondeur maximale est cherchée parmi trois, cinq et huit niveaux. Le nombre minimal d'observations par feuille est fixé à deux mille, montant jugé nécessaire sur des rendements mensuels dont la part imprévisible domine, sinon une feuille contenant quelques dizaines de titres-mois mémoriserait du bruit.

Le dernier paramètre, la fraction de prédicteurs tirée à chaque nœud, fait l'objet d'une recherche en deux temps plutôt que d'un produit cartésien avec les précédents. Dans un premier temps, cette fraction est fixée à 0,33, valeur correspondant à la règle historique de Breiman (2001) en régression, et la grille des trois autres axes est parcourue entièrement. Dans un second temps, la combinaison gagnante est figée et seule la fraction varie sur les valeurs 0,66 et 1,00. Le modèle retenu pour la fenêtre est le meilleur des deux étapes. On note que la valeur 1,00 ramène la forêt à du *bagging* pur, c'est que la décorrélation des arbres n'apporte rien sur ces données.

4.3.4 Le *gradient boosting*

Le quatrième modèle utilise également des arbres, mais les construit selon une logique opposée. Là où la forêt agrège des arbres profonds et indépendants pour réduire la variance, le *gradient boosting* (Friedman, 2001) empile des arbres peu profonds et dépendants les uns des autres pour réduire le biais. Le modèle s'écrit comme une somme construite pas à pas,

$$F_m(\mathbf{z}) = F_{m-1}(\mathbf{z}) + \nu h_m(\mathbf{z}), \quad m = 1, \dots, M, \quad (4.10)$$

où chaque arbre h_m est ajusté sur l'opposé du gradient de la perte évalué au modèle courant, c'est-à-dire, sous perte quadratique, sur les résidus $r_{i,t+1} - F_{m-1}(\mathbf{z}_{i,t})$. Le taux d'apprentissage ν pondère chaque contribution. Chaque arbre ne corrige donc qu'une fraction de ce que le modèle précédent n'expliquait pas.

Les implémentations modernes ajoutent une régularisation explicite de la complexité des arbres à l'objectif (Chen and Guestrin, 2016) :

$$\mathcal{L} = \sum_{(i,t)} \ell(r_{i,t+1}, F_M(\mathbf{z}_{i,t})) + \sum_{m=1}^M \Omega(h_m), \quad \Omega(h) = \gamma J + \frac{\lambda}{2} \|w\|_2^2 + \alpha \|w\|_1, \quad (4.11)$$

où J est le nombre de feuilles de l'arbre et w le vecteur des valeurs qu'il leur attribue. J'utilise LightGBM (Ke et al., 2017). La croissance se fait feuille par feuille, en développant à chaque étape celle qui promet la plus forte réduction de perte, sous une contrainte portant sur le nombre total de feuilles plutôt que sur la profondeur. Les valeurs des prédicteurs sont discrétisées en classes, ce qui ramène la recherche de la meilleure coupure à un parcours d'histogramme. Deux optimisations supplémentaires, l'échantillonnage des observations selon l'amplitude de leur gradient et le regroupement des variables qui ne sont jamais non nulles simultanément, réduisent encore le coût sur les jeux de données volumineux.

Hyperparamètres. Le nombre de feuilles par arbre est cherché parmi trois, sept et quinze, ce qui correspond à des arbres de deux à quatre niveaux de profondeur effective. Le taux d'apprentissage est fixé à 0,01, une valeur faible qui impose de construire beaucoup d'arbres mais rend la trajectoire d'apprentissage moins brutale. Le nombre minimal d'observations par feuille est de deux mille, comme pour la forêt et pour la même raison. Les paramètres de régularisation α et λ de l'équation (4.11) valent chacun 0,1, et une fraction de 0,7 des prédicteurs et des observations est tirée à chaque itération, ce qui introduit dans le *boosting* une randomisation analogue à celle de la forêt.

Le budget d'arbres est fixé à deux mille, mais il n'est pratiquement jamais atteint : la construction s'interrompt dès que l'erreur mesurée sur le bloc de validation cesse de s'améliorer pendant deux cents itérations consécutives. Cet arrêt anticipé est le principal

mécanisme de régularisation du modèle, et il joue exactement le rôle que le paramètre α joue pour l'Elastic Net.

TABLE 4.1 – Grilles d'hyperparamètres explorées sur chaque fenêtre.

Modèle	Paramètre	Valeurs explorées
Régression linéaire	aucun hyperparamètre	
Elastic Net	α	10^{-4} et 10^{-3}
	ρ	0,1 ; 0,3 ; 0,5 ; 0,7 ; 0,9
	itérations	1 000 au maximum (fixé)
Forêt aléatoire	arbres	300 (fixé)
	profondeur	3 ; 5 ; 8
	effectif minimal	2 000 (fixé)
	fraction de variables	0,33 puis 0,66 et 1,00 (recherche en deux temps)
LightGBM	feuilles	3 ; 7 ; 15
	taux d'apprentissage	0,01 (fixé)
	effectif minimal	2 000 (fixé)
	budget d'arbres	2 000, avec arrêt après 200 itérations sans amélioration

4.3.5 Mesures d'importance des variables

Les quatre modèles n'offrent pas la même lecture de la contribution de chaque prédicteur. Trois mesures sont retenues, adaptées chacune à une famille. La première s'applique au cadre linéaire, les deux suivantes aux modèles arborescents.

Les modèles linéaires Via la procédure de [Fama and MacBeth \(1973\)](#) qui consiste à régression transversale est estimée séparément pour chaque mois, on identifie les contributions des caractéristiques.

$$r_{i,t+1} = \lambda_{0,t} + \boldsymbol{\lambda}_t^\top \tilde{\mathbf{c}}_{i,t} + u_{i,t+1}, \quad (4.12)$$

puis la contribution moyenne de chaque caractéristique est estimée par la moyenne temporelle des coefficients mensuels, $\bar{\lambda}_p = T^{-1} \sum_t \hat{\lambda}_{p,t}$. Exprimée en rendement mensuel, cette quantité mesure la rémunération associée à un écart d'une unité de rang sur la caractéristique p , les autres caractéristiques tenues fixes. Comme les coefficients mensuels sont autocorrélés, leur écart-type est estimé par la matrice de covariance de [Newey and West \(1987\)](#), avec un nombre de retards fixé par la règle automatique de [Newey and West \(1994\)](#), soit $\lfloor 4(T/100)^{2/9} \rfloor$.

Les huit variables macroéconomiques en sont exclues puisqu'elles sont constantes à l'intérieur d'un mois, elles sont parfaitement colinéaires avec la constante de la régression

transversale, et leur coefficient n'est pas identifiable. Cette procédure est estimée sur l'ensemble du panel et non fenêtre par fenêtre et ne sert qu'à identifier l'importance des variables.

Un modèle arborescent ne fournit pas de coefficients. Cependant d'autres valeurs permettent d'examiner l'impact des prédicteurs.

La première est l'importance interne des variables. Pour la forêt, elle est calculée comme la réduction totale de l'impureté attribuable aux coupures portant sur chaque variable et pour le *gradient boosting*, comme le gain cumulé de ces coupures, complété par le décompte du nombre de coupures. Un désavantage de ces mesures montré par Strobl et al. (2007) est qu'elles favorisent les variables offrant beaucoup de points de coupure possibles, donc les variables continues sur les variables ou à forte cardinalité, indépendamment de leur pouvoir prédictif réel. Elles ne disent rien non plus du sens de l'effet. C'est qu'intervient la seconde valeur, la valeur de Shapley, issue de la théorie des jeux coopératifs (Shapley, 1953). Elle a trouvé son utilité à l'interprétation des modèles par Lundberg and Lee (2017), elle attribue à chaque prédicteur la contribution. L'algorithme de Lundberg et al. (2020) rend ce calcul praticable sur des ensembles d'arbres, dont le coût serait sinon exponentiel. Ces valeurs sont calculées sur un échantillon du bloc de test de la dernière fenêtre, plus petit pour la forêt que pour le *gradient boosting* en raison de la taille des arbres.

4.4 Construction de portefeuille

4.4.1 Portefeuilles triés par décile

À chaque mois t de la période de test, les titres sont classés par rendement prédit et répartis en dix groupes d'effectifs égaux. Le décile 1 rassemble les prévisions les plus faibles, le décile 10 les plus élevées. Le rendement du décile d au mois $t + 1$ est la moyenne des rendements excédentaires réellement réalisés par les titres qui le composent :

$$r_{t+1}^{(d)} = \frac{1}{|\mathcal{D}_{d,t}|} \sum_{i \in \mathcal{D}_{d,t}} r_{i,t+1}, \quad (4.13)$$

et le portefeuille long-short achète le décile supérieur en finançant cet achat par la vente à découvert du décile inférieur :

$$r_{t+1}^{\text{LS}} = r_{t+1}^{(10)} - r_{t+1}^{(1)}. \quad (4.14)$$

Le classement est refait chaque mois sur la population disponible dans ce mois et ne dépend que de l'ordre des prévisions, et non de leur niveau. Enfin, la position vendeuse

annule approximativement l'exposition au marché, de sorte que le rendement obtenu ne dépend que faiblement de la direction générale des cours sur la période. Si le classement produit par un modèle contient de l'information, ce rendement doit croître de façon globalement monotone du décile 1 au décile 10.

4.4.2 Mesures de performance

Sur la série mensuelle $\{r_t^{\text{LS}}\}$ obtenue en mettant bout à bout les blocs de test de toutes les fenêtres, les mesures suivantes sont calculées. Comme les rendements sont déjà excédentaires, aucun taux sans risque n'est retranché une seconde fois.

Par souci de simplicité le rendement et la volatilité annualisés valent $12\bar{r}$ et $\sqrt{12}\hat{\sigma}$ avec $\bar{r}$ le rendement moyen mensuel et $\hat{\sigma}$ l'écart-type du rendement. Le ratio de Sharpe peut donc s'écrire comme :

$$\widehat{SR} = \sqrt{12} \frac{\bar{r}}{\hat{\sigma}}. \quad (4.15)$$

Le ratio de Sortino ([Sortino and Price, 1994](#)) remplace la volatilité par une mesure de dispersion qui ne retient que les mois négatifs,

$$\widehat{DD} = \sqrt{12} \sqrt{\frac{1}{T} \sum_{t=1}^T \min(r_t, 0)^2}, \quad \widehat{SO} = \frac{12\bar{r}}{\widehat{DD}}, \quad (4.16)$$

Contrairement au ratio de Sharpe qui pénalise l'ensemble de la volatilité, le ratio de Sortino ne sanctionne que la volatilité baissière. Il évite ainsi d'assimiler les rendements fortement positifs à une prise de risque pénalisable.

La perte maximale se lit sur la courbe de richesse cumulée $W_t = \prod_{s \leq t} (1 + r_s)$:

$$\text{MDD} = \min_t \left(\frac{W_t}{\max_{s \leq t} W_s} - 1 \right). \quad (4.17)$$

La significativité du rendement moyen est testée par la statistique $t = \bar{r}/(\hat{\sigma}/\sqrt{T})$.

4.4.3 Constructions alternatives

La construction décrite plus haut, long-short équipondéré sur les déciles extrêmes, reste la référence du mémoire. On teste des variantes en plus, en gardant les prévisions intactes, pour mesurer comment les résultats varient quand on change la façon de transformer ces prévisions en portefeuille plutôt que modèle lui-même.

La première remplace la pondération égale par une pondération proportionnelle à la capitalisation boursière, connue à la date de formation. Un portefeuille équipondéré investit autant sur le plus petit titre de l'univers que sur le plus grand. Un écart important entre les deux pondérations indique que la performance se concentre sur le bas de l'univers.

La seconde supprime la position vendeuse et ne conserve que les deux déciles supérieurs de chaque mois. Beaucoup d'investisseurs institutionnels ne peuvent pas vendre à découvert, on teste donc une stratégie dont ils auraient eu accès en réalité. Ce portefeuille conserve l'exposition au marché que le long-short neutralise, et son ratio de Sharpe doit être comparé à celui du marché, non à celui du long-short.

4.5 Combiner les modèles plutôt que choisir

Soient deux prévisions dont les erreurs ont pour variances σ_1^2 et σ_2^2 et pour corrélation ρ . La variance de l'erreur de leur combinaison, de poids w et $1 - w$, est

$$\sigma^2(w) = w^2\sigma_1^2 + (1 - w)^2\sigma_2^2 + 2w(1 - w)\rho\sigma_1\sigma_2, \quad (4.18)$$

et elle est minimisée pour

$$w^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}. \quad (4.19)$$

Le résultat de [Bates and Granger \(1969\)](#) est analogue à celui de la diversification d'un portefeuille : combiner des prévisions peut réduire l'erreur dès lors que celles-ci ne sont pas parfaitement redondantes.

La combinaison porte sur les prévisions déjà enregistrées, sans aucun ré-entraînement. Deux règles produisent des poids constants sur toute la période. La pondération égale attribue $1/K$ à chacun des K modèles. La pondération par le R^2 de validation attribue à chaque modèle un poids proportionnel à $\max(R_{\text{val},m}^2, 0)$, ce qui utilise une information issue des données sans jamais toucher au bloc de test.

La pondération par moindres carrés suit [Granger and Ramanathan \(1984\)](#) et retient les poids qui minimisent l'erreur de la combinaison elle-même, ce qui revient à régresser le rendement réalisé sur les prévisions des modèles.

La pondération égale est difficile à battre et [Smith and Wallis \(2009\)](#) en donnent une explication simple, en effet les poids estimés sont eux-mêmes des variables aléatoires, et le bruit de leur estimation coûte souvent plus cher que ce que l'optimisation rapporte. [Rapach et al. \(2010\)](#) retrouvent ce résultat sur la prévision de la prime de risque agrégée, où de simples moyennes de prévisions individuelles surpassent des méthodes plus élaborées.

4.6 Analyse par capitalisation

Les prévisions déjà produites sont réévaluées séparément à l'intérieur de chaque segment de capitalisation. Aucun modèle n'est ré-entraîné.

Le découpage retenu est en terciles de capitalisation, recalculés mois par mois sur la population du mois. À l'intérieur de chaque segment, les déciles de prévision sont eux aussi recalculés pour chaque portefeuille.

Le groupe d'un titre est réattribué chaque mois, jamais fixé sur une date précise. Le classer selon sa capitalisation moyenne ou finale sur toute la période utiliserait une information du futur, une fuite qu'on cherche à éviter. En résulte le fait que le nombre d'entreprises distinctes vues dans un groupe sur l'ensemble de la période dépasse son effectif à une date donnée.

Les trois segments n'ayant pas la même volatilité, leurs R^2 ne sont pas comparables entre eux pour la raison exposée à la section 4.4.2. La comparaison entre groupes repose donc sur le coefficient d'information de l'équation (4.5) et sur le ratio de Sharpe.

4.7 Horizon de prévision de douze mois

Une piste parallèle est de remplacer la cible du rendement du mois prochain par le rendement des douze mois suivants.

Un horizon plus long agrège davantage de rendement pour une même quantité de bruit mensuel, ce qui peut rendre la composante prévisible plus visible. Il correspond aussi à un horizon de décision plus réaliste pour beaucoup d'investisseurs.

4.7.1 Définition de la cible

La cible composée s'écrit

$$r_{i,t}^{(H)} = \prod_{k=1}^H (1 + R_{i,t+k}) - \prod_{k=1}^H (1 + R_{t+k}^f), \quad H = 12. \quad (4.20)$$

Les rendements du titre et le taux sans risque sont capitalisés séparément, puis soustraits l'un de l'autre, choix cohérent avec la cible précédente à un mois de l'équation (3.1).

4.7.2 Embargo aux frontières des blocs

Une cible portant sur douze mois crée une fuite que l'ordre chronologique des blocs (entraînement/validation/test) ne suffit pas à empêcher. La cible associée aux derniers mois du bloc d'entraînement porte sur des rendements qui appartiennent au bloc de validation, et la même chose vaut entre validation et test. Le modèle s'entraînerait donc sur de l'information provenant du bloc suivant. La solution est la purge des frontières (López de Prado, 2018) où les H derniers mois de chaque bloc d'entraînement et de validation sont retirés.

4.7.3 Titres radiés

Lorsque l'historique d'un titre s'arrête avant la fin de la période, à la suite d'une faillite ou d'un rachat, la fenêtre de douze mois des dernières dates de formation déborde au-delà de la dernière cotation.

Écarter purement et simplement ces observations serait la solution la plus simple et la plus fautive. La disparition d'une entreprise est corrélée à sa performance, et les retirer reviendrait à supprimer précisément les observations dont le rendement à douze mois est le plus négatif. Le modèle ne serait alors entraîné et évalué que sur des titres qu'on sait qui ont survécu, ce qui constitue un biais de survie.

De plus on ne distingue pas avec la base de données si l'entreprise disparaît à cause d'une faillite ou à cause d'une fusion donc on considère que la position est liquidée au dernier rendement observé, puis placée au taux sans risque jusqu'à la fin de l'horizon. Pour une date entièrement postérieure à une radiation, la cible de l'équation (4.20) vaut alors exactement zéro et est donc neutre en rendement excédentaire.

4.7.4 Chevauchement des observations

C'est la difficulté principale de cet horizon. Deux dates de formation consécutives partagent onze mois de rendement, donc leurs cibles sont fortement autocorrélées par construction. Hansen and Hodrick (1980) ont montré les premiers ce que cela implique pour l'inférence, et Boudoukh et al. (2008) rappellent qu'une grande partie de la prévisibilité apparente à long horizon documentée dans la littérature s'explique par ce chevauchement plutôt que par un signal supplémentaire.

4.7.5 Constructions de portefeuille

On teste dans cette analyse plusieurs constructions de portefeuille. La construction à rebalancement mensuel reprend exactement la mécanique de la section 4.4. Chaque mois, les titres sont classés selon la prévision à douze mois, détenus un mois, et le rendement pris en compte est le rendement excédentaire mensuel réalisé. La prévision longue ne sert que de signal de classement. Cette construction ne respecte pas l'horizon de détention implicite de la cible, mais elle a une propriété que les deux autres n'ont pas : seul le signal change par rapport au dispositif principal, ce qui rend la comparaison entre les deux horizons possible toutes choses égales par ailleurs. C'est pour cette raison qu'elle sert de référence.

La construction à cohortes chevauchantes suit la convention de Jegadeesh and Titman (1993). Chaque mois, une cohorte est formée et détenue douze mois, et le rendement du mois courant est la moyenne des rendements mensuels des douze cohortes encore actives. La série obtenue est mensuelle et s'annualise donc normalement, tout en respectant

l'horizon de détention. Elle correspond à une stratégie réellement implémentable, dans laquelle un douzième du capital est investi chaque mois.

La construction à rebalancement annuel n'utilise qu'une date de formation par an et aucune observation ne se chevauche cependant elle divise par douze le nombre d'observations disponibles.

Le R^2 hors échantillon n'est pas davantage comparable entre les deux horizons, la variance de la cible changeant d'un facteur considérable. La comparaison passe là encore par l'équation (4.5) et par les mesures de portefeuille.

4.8 Alpha et coûts

4.8.1 Alpha contre un modèle à six facteurs

Une stratégie fondée sur l'apprentissage peut être exposée au *momentum*, à la taille ou à la valeur or si c'est le cas n'apporte pas la même contribution qu'une stratégie dégageant un rendement ajusté du risque significatif (Jensen, 1968). On mesure donc ces expositions et estimons un alpha après contrôle des principaux facteurs de risque.

Le portefeuille long-short est donc régressé sur les cinq facteurs de Fama and French (2015) ainsi que du *momentum* de Carhart (1997). Les six facteurs sont issus de données de Kenneth French, version mensuelle.

$$r_t^{\text{LS}} = \alpha + \beta' \mathbf{F}_t + \varepsilon_t, \quad \mathbf{F}_t = (\text{MKT}_t, \text{SMB}_t, \text{HML}_t, \text{RMW}_t, \text{CMA}_t, \text{MOM}_t)'. \quad (4.21)$$

L'ordonnée à l'origine α est le rendement que les facteurs n'expliquent pas, au sens de Jensen (1968). Les modèles utilisent des caractéristiques dont plusieurs, `mve11`, `bm`, `mom12m`, `operprof` et `agr`, servent à construire SMB, HML, RMW, CMA et MOM¹. On s'attend donc à avoir une partie de la performance expliquée par ces facteurs.

Le ratio d'information rapporte l'alpha à la volatilité du résidu,

$$\widehat{IR} = \frac{12 \hat{\alpha}}{\sqrt{12} \hat{\sigma}_\varepsilon}. \quad (4.22)$$

Il permet de comparer un modèle à l'autre lorsque les portefeuilles n'ont pas la même volatilité.

1. SMB (*Small Minus Big*, taille), HML (*High Minus Low*, valeur), RMW (*Robust Minus Weak*, rentabilité) et CMA (*Conservative Minus Aggressive*, investissement) sont les facteurs de Fama and French (2015); MOM (*Momentum*) est le facteur de continuation de Carhart (1997).

4.8.2 Rotation du portefeuille

La rotation se mesure sur les poids individuels de mois en mois. Deux mois consécutifs peuvent afficher le même rendement de décile avec un portefeuille entièrement renouvelé.

Un portefeuille formé fin t avec les poids $w_{i,t}$ n'est pas touché pendant le mois suivant, et pourtant ses poids se déforment, la part de chaque titre augmentant ou diminuant selon qu'il sur-performe ou sous-performe le portefeuille.

$$w_{i,t}^+ = \frac{w_{i,t} (1 + r_{i,t+1})}{\sum_j w_{j,t} (1 + r_{j,t+1})}. \quad (4.23)$$

La rotation ne compte que l'écart entre les poids voulus et les poids déjà détenus,

$$TO_{t+1} = \sum_i |w_{i,t+1} - w_{i,t}^+|. \quad (4.24)$$

Un titre maintenu au même poids ne coûte rien, un titre entrant coûte son poids entier, un titre sortant coûte le poids qu'il avait. Un décile intégralement renouvelé vaut 2, les deux déciles se cumulant.

La rotation se décompose exactement en deux termes selon que le titre est présent aux deux dates ou non,

$$TO_{t+1} = \underbrace{\sum_{i \notin \mathcal{H}_t \cap \mathcal{H}_{t+1}} |w_{i,t+1} - w_{i,t}^+|}_{\text{entrées et sorties}} + \underbrace{\sum_{i \in \mathcal{H}_t \cap \mathcal{H}_{t+1}} |w_{i,t+1} - w_{i,t}^+|}_{\text{rééquilibrage}}, \quad (4.25)$$

où $\mathcal{H}_t$ désigne l'ensemble détenu en t . Dans le premier terme, l'un des deux poids est toujours nul par construction. De plus, dû au second terme, un portefeuille qui a ses deux déciles inchangés entre deux mois va avoir un turnover positif (à l'exception que tous les titres varient de même proportion).

4.8.3 Frais de transaction et coût d'emprunt

Deux frais distincts s'appliquent, le premier correspond aux frais dus au turnover du portefeuille, le second lorsqu'il existe une position vendeuse.

Les frais de transaction sont proportionnels au montant échangé et se soustraient du rendement du mois où l'ordre est passé et le coût d'emprunt est un loyer mensuel indépendant de toute transaction,

$$r_t^{\text{net}} = r_t^{\text{LS}} - c \cdot TO_t - \frac{\phi}{12}, \quad (4.26)$$

avec c le coût de transaction et ϕ le taux d'emprunt annuel.

Vendre un titre à découvert suppose de l'emprunter, et le prêteur facture une com-

mission pour ce service. Par hypothèse, le taux retenu est de 30 points de base annuels (DeMiguel et al., 2009), qui correspond à des titres liquides et largement détenus. Un taux uniforme sous-estime le prix des titres difficiles à emprunter, surtout ceux du décile 1, mais on n’explore pas plus.

De même, les frais de transaction reposent sur des hypothèses différentes selon la pondération, avec 40 points de base pour l’équipondéré contre 15 pour la pondération par capitalisation. Étant donné que l’équipondération fait mettre un capital beaucoup plus élevé pour les petites capitalisations comparé à la pondération par capitalisation, sachant qu’un titre moins liquide engendre des frais de transaction plus élevés, on attribue donc à cette configuration des coûts plus élevés. En accord avec Novy-Marx and Velikov (2016) montrent que les coûts effectifs varient d’un ordre de grandeur avec la taille.

4.8.4 Coût de seuil de rentabilité

Fixer un frais particulier reste contestable, on cherche donc ici à trouver le coût qui ramène à 1,96 la statistique t du rendement moyen net, soit la valeur c^* vérifiant

$$t(c^*) = 1,96, \quad t(c) = \frac{\overline{r^{\text{LS}}} - c \cdot TO - \phi/12}{\hat{\sigma}(\overline{r^{\text{LS}}} - c \cdot TO) / \sqrt{T}}. \quad (4.27)$$

Aucune expression fermée n’existe, le coût figurant à la fois au numérateur et au dénominateur. Le seuil est obtenu par dichotomie sur l’intervalle de recherche.

Ce chiffre présente l’avantage de ne dépendre d’aucune hypothèse sur le niveau réel des frais. Il inverse la question, en indiquant jusqu’où les coûts peuvent monter avant que la performance cesse d’être significative.

Chapitre 5

Résultats

5.1 L'échantillon obtenu

5.1.1 Fusion des trois sources

Le panel utilisé pour l'étude résulte de la fusion des caractéristiques d'entreprise, rendements mensuels par titre, et prédicteurs macroéconomiques.

Avant fusion, les caractéristiques couvrent 29 731 entreprises sur 504 mois (janvier 1980 à décembre 2021), les rendements 38 297 entreprises sur 828 mois (janvier 1956 à décembre 2024), et les séries macroéconomiques 552 mois. 99,75% des entreprises présentes dans les caractéristiques y étaient aussi dans les rendements.

Le panel fusionné compte donc 3 321 940 observations et 29 657 entreprises, de février 1980 à décembre 2021, sans aucun doublon sur le couple entreprise-mois.

5.1.2 La variable cible

Le tableau 5.1 donne la distribution du rendement excédentaire sur le panel fusionné.

TABLE 5.1 – Statistiques descriptives du rendement excédentaire mensuel

Statistique	Valeur
Observations	3 321 940
Moyenne	+0,746 %
Écart-type	18,22 %
Minimum	−99,52 %
1 ^{er} quartile	−6,51 %
Médiane	−0,18 %
3 ^e quartile	+6,28 %
Maximum	+2399,66 %

Note. Rendement excédentaire mensuel, calculé sur le panel fusionné avant filtrage de l'univers.

Avec une moyenne mensuelle de 0,75 % pour un écart-type de 18,2 %, le rapport signal sur bruit est notablement bas, de l'ordre de 1 à 24.

Ensuite, la distribution est asymétrique à droite, avec un maximum à +2400 % contre un minimum borné à −100 %. La médiane est légèrement négative alors que la moyenne est positive. Cela signifie qu'il y a quelques titres ayant des valeurs extrêmes qui tirent la moyenne vers le haut.

5.1.3 Filtrage de l'univers investissable

Comme mentionné dans la section 3.3.4, deux filtres successifs sont utilisés sur notre panel : la capitalisation boursière et l'illiquidité.

TABLE 5.2 – Effet cumulé des filtres sur l'univers

Étape	Observations	Entreprises	Retiré (%)
Panel fusionné	3 321 940	29 657	—
Capitalisation manquante retirée	3 320 843	29 652	0,03
Filtre de capitalisation (10 ^e centile)	2 988 598	28 664	10,00
Illiquidité manquante retirée	2 906 647	28 087	2,47
Filtre d'illiquidité (90 ^e centile)	2 615 807	27 556	10,01
Panel prêt pour la modélisation	2 615 807	27 556	21,26

Le panel final compte 2 615 807 observations titre-mois portant sur 27 556 entreprises. Sur la seule période de test (2010–2021), il y a 10 080 entreprises distinctes.

5.1.4 Imputation, winsorisation et transformation en rang

J'ai écarté les lignes dont les valeurs de capitalisation et d'illiquidité manquaient, il faut donc maintenant traiter le reste des 28 caractéristiques qui ont elles aussi potentiellement des valeurs manquantes. Elles sont imputées par la médiane du mois, ou en cas d'absence du mois entier par la médiane globale de la colonne. L'imputation intervient logiquement après les filtres pour que la médiane soit calculée sur la population concernée, non sur une population plus large incluant des titres qu'on vient d'exclure.

TABLE 5.3 – Part de valeurs manquantes avant imputation par tranche

Caractéristiques concernées	Manquant (%)
acc, invest	30 à 35
chtx, operprof, roeq, roaq, gma, chcscho, cfp, egr, agr	25 à 30
bm, sp, ep	20 à 25
beta, idiovol, mom12m, chmom	5 à 10
mom6m, turn, dolvol	1 à 5
mom1m, retvol, std_turn, indmom, baspread, maxret, zerotrade, ill, mvel1	< 1

On remarque dans le tableau 5.3 que les caractéristiques comptables sont imputées sur près d'un tiers de leurs lignes.

Chaque caractéristique est ensuite winsorisée à ses premier et quatre-vingt-dix-neuvième centiles, calculés séparément pour chaque mois, puis remplacée par son rang parmi les entreprises du même mois, ramené dans l'intervalle $[-1, +1]$.

5.2 Précision hors échantillon des modèles

5.2.1 Fenêtre glissante ou fenêtre extensive

Les deux façons de faire avancer le bloc d'entraînement décrites à la section 4.2.3 ont été estimées intégralement sur les mêmes paramètres, la seule différence étant donc la taille du bloc d'entraînement qui varie selon la spécification du type de fenêtres. En mode glissant elle reste comprise entre 1,1 et 1,3 million d'observations, tandis qu'en mode extensif elle passe de 1,1 million sur la fenêtre 2010 à 2,33 millions sur la fenêtre 2021. Tout écart entre les deux colonnes du tableau 5.4 n'est donc dû qu'au type de la fenêtre.

TABLE 5.4 – Fenêtre glissante contre fenêtre extensive, sur les mêmes 144 mois de test

Modèle	Fenêtre glissante			Fenêtre extensive		
	R^2_{oos} (%)	Sharpe	DD max	R^2_{oos} (%)	Sharpe	DD max
Régression linéaire	0,27	1,22	−11,3 %	0,26	1,06	−11,5 %
Elastic Net	0,39	0,77	−19,8 %	0,36	0,65	−34,9 %
LightGBM	0,48	1,22	−19,9 %	0,35	0,74	−48,9 %
Random Forest	0,49	1,13	−20,9 %	0,49	0,79	−49,1 %

Note. R^2_{oos} de test agrégé sur les douze fenêtres selon l'équation (4.4). Le ratio de Sharpe et le drawdown maximum sont ceux du portefeuille long-short équipondéré décile 10 moins décile 1 construit à la section 5.4, sur les 144 mois de test communs aux deux protocoles.

Le R^2_{oos} départage mal les deux protocoles car il est très proche pour les deux approches et ceci pour chaque modèle à l'exception du LightGBM qui a un écart substantiel. Quoique non présenté dans le tableau 5.4 le même constat a été fait sur les blocs de validation où l'écart entre les deux modes n'excède jamais deux points de base pour tout modèle.

On s'est donc tourné vers le portefeuille pour trancher. Le ratio de Sharpe de la fenêtre glissante est supérieur pour les quatre modèles, avec un écart pour les deux modèles non linéaires de 1,22 contre 0,74 pour LightGBM, 1,13 contre 0,79 pour la forêt aléatoire. Le drawdown maximum raconte la même histoire passant de près de −49 % à environ −20 %.

Tous les résultats des sections suivantes donc reposent sur la fenêtre glissante.

5.2.2 R^2 hors échantillon poolé

Le R^2_{oos} est calculé en agrégeant d'abord les prédictions des douze fenêtres, puis en appliquant l'équation (4.4) à la série complète.

Les quatre modèles dégagent un R^2_{oos} positif sur le test, compris entre 0,27 % et 0,49 % avec les deux modèles non linéaires devançant les deux modèles linéaires. L'écart entre le meilleur et le pire modèle est de vingt-deux points de base de R^2 mensuel. Il y a bien un gain apporté par la linéarité mais il vient avec un coût computationnel, en effet l'entraînement complet demande 61 secondes pour la régression linéaire, 712 secondes pour

TABLE 5.5 – R^2_{oos} agrégé sur les douze fenêtres (en %)

Modèle	Train	Validation	Test	Écart train – test
Régression linéaire	0,46	0,14	0,27	+0,19
Elastic Net	0,33	0,22	0,39	−0,06
LightGBM	1,06	0,40	0,48	+0,58
Random Forest	0,66	0,26	0,49	+0,18

l'Elastic Net, 1 119 secondes pour LightGBM et près de cinq heures (17 913 secondes) pour la forêt aléatoire.

Gu et al. (2020) obtiennent sur le marché américain un R^2_{oos} mensuel de $-3,46$ % pour une régression linéaire classique, $0,11$ % pour l'Elastic Net et $0,33$ % pour la forêt aléatoire. Pinelis and Ruppert (2023) rapportent sur 1990–2020 des valeurs de $0,07$ %, $0,22$ % et $0,19$ % pour ces trois mêmes modèles. Sur le marché européen, Fieberg et al. (2023) obtiennent $0,43$ % pour les moindres carrés, $0,37$ % pour l'Elastic Net, $0,58$ % pour la forêt aléatoire et $0,60$ % pour le *gradient boosting* (GBRT). Les valeurs du tableau 5.5 sont du même ordre, et supérieures à la plupart d'entre elles cependant ces différences peuvent être expliquées par les variables, les périodes et les univers qui diffèrent d'une étude à l'autre. Si on prend pour exemple la régression linéaire sans pénalisation de Gu et al. (2020) sur 920 variables, la nôtre en compte trente.


Enfin, l'écart entre train et test renseigne sur le sur-apprentissage. Il est le plus large pour LightGBM ($+0,58$ point), ce qui est attendu d'un modèle de *gradient boosting* capable de mémoriser du bruit.

5.2.3 Évolution fenêtre par fenêtre

Le R^2 fluctue considérablement dans le temps.

Sur le graphique 5.1 on remarque une synchronisation entre les quatre modèles. L'année 2013 est la meilleure pour tous les quatre, avec des R^2 de $+2,4$ % à $+2,7$ % et l'année 2018 est la pire pour tous, entre $-1,5$ % et $-1,9$ % et trois autres années (2011, 2014, 2015) sont négatives quel que soit le modèle.

Wolff and Neugebauer (2019) observent la même chose en 2013 qu'ils qualifient d'une année dorée de prévisibilité. Grammig et al. (2025) relèvent un effondrement collectif comparable en 2015, une année où nos quatre modèles sont également négatifs. Kurucan and Hepşen (2025) attribuent ce comportement à l'instabilité des paramètres : les changements de régime bouleversent les relations entre variables explicatives et rendements, et la structure apprise à l'entraînement devient caduque.

FIGURE 5.1 – Évolution du R_{oos}^2 de test, fenêtre par fenêtre, pour les quatre modèles.

5.2.4 Hyperparamètres retenus d'une fenetre à l'autre

Les hyperparamètres sont choisis sur la validation propre à chaque fenetre. Le tableau 5.6 rassemble les configurations retenues.

TABLE 5.6 – Hyperparamètres retenus par fenetre

Année de test	Elastic Net		LightGBM		Random Forest
	α	ℓ_1 -ratio	Feuilles	Arbres construits	Profondeur
2010	0,0001	0,3	15	1 985	8
2011	0,001	0,1	7	1 893	8
2012	0,001	0,3	7	1 138	8
2013	0,001	0,9	15	54	5
2014	0,001	0,9	7	519	5
2015	0,001	0,9	15	490	3
2016	0,001	0,9	3	150	5
2017	0,001	0,7	7	135	5
2018	0,001	0,9	15	62	3
2019	0,001	0,9	15	41	5
2020	0,001	0,9	15	14	3
2021	0,001	0,9	15	373	3

Dans le tableau 5.6 les modèles à hyperparamètres choisissent des configurations de plus en plus régularisées à mesure que les fenêtres avancent. L'Elastic Net passe d'un ℓ_1 -ratio de 0,1 à 0,3 sur les trois premières fenêtres à 0,9 sur les huit dernières, c'est-à-dire d'un comportement de type Ridge, qui ne fait que rétrécir les coefficients sans annuler aucun, à un comportement de type Lasso, qui peut en annuler. Le commentaire du paragraphe précédent montre aussi que la régularisation sévère se faisait aussi sur l'hyperparamètre alpha. La profondeur retenue par la forêt aléatoire décroît de 8 à 3, la

valeur 3 n'apparaissant qu'à partir de la fenêtre 2015. En ce qui concerne le LightGBM, le nombre d'arbres que l'arrêt anticipé laisse construire chute de 1 985 sur la fenêtre 2010 à 14 sur la fenêtre 2020. Passé la fenêtre 2013, aucune fenêtre n'en construit plus de 520.

On voit donc que tous nos modèles ayant des hyperparamètres pointent vers une même conclusion que le signal dégagé par les prédicteurs se fait de plus en plus faible plus la période de validation est récente.

5.3 Contribution des variables

5.3.1 Significativité des caractéristiques

Comme mentionné à la section 4.3.1, nous employons la procédure de [Fama and MacBeth \(1973\)](#). Une régression en coupe transversale est estimée sur chacun des 503 mois du panel, ce qui fournit pour chaque caractéristique une série temporelle de 503 coefficients. Nous testons ensuite la nullité de la moyenne temporelle de cette série, en estimant l'écart-type de cette moyenne par la méthode de Newey-West à cinq retards, robuste à l'autocorrélation des primes et à l'hétéroscédasticité.

Cette analyse est descriptive et porte sur tout l'historique disponible (1980–2021) et elle a pour objectif d'identifier les caractéristiques durablement associées au rendement futur, elle n'est en aucun cas utilisée lors d'une tentative de prédiction.




FIGURE 5.2 – Vingt caractéristiques les plus significatives selon les régressions de Fama-MacBeth, classées par $|t|$ de Newey-West.

Quinze prédicteurs sur trente sont significatifs au seuil de 5 %. Le détail chiffré figure dans le tableau de l'annexe A.3.

La plupart des signes sont conformes aux régularités documentées. La volatilité des rendements (`retvol`) est associée négativement au rendement futur, comme chez [Ang et al. \(2006\)](#), de même que le retournement à court terme (`mom1m`) chez [Jegadeesh \(1990\)](#). Le momentum à six et douze mois (`mom6m`, `mom12m`) ressort au contraire positivement, comme chez [Jegadeesh and Titman \(1993\)](#), ainsi que le momentum sectoriel (`indmom`) documenté par [Moskowitz and Grinblatt \(1999\)](#). La rotation du flottant (`turn`) est négativement liée au rendement futur, résultat obtenu par [Datar et al. \(1998\)](#), tout comme le volume échangé en dollars (`dolvol`) chez [Chordia et al. \(2001\)](#). La rentabilité brute (`gma`) est positive, conformément à [Novy-Marx \(2013\)](#).

L'illiquidité d'Amihud (`ill`) est associée négativement au rendement futur ($\bar{\gamma} = -0,0053$, $t = -3,13$) alors que [Amihud \(2002\)](#) documente une prime d'illiquidité, donc une relation positive. Le nombre de jours sans transaction (`zerotrade`, $\bar{\gamma} = -0,0057$, $t = -5,89$) présente la même inversion vis-à-vis de [Liu \(2006\)](#). Une explication potentielle de ce phénomène pourrait être le filtre de liquidité de la section 3.3.4 où on aurait donc enlevé les entreprises pour lesquelles cette prime se manifeste.

La croissance de l'actif (`agr`) constitue le second écart. Elle est ici associée positivement au rendement futur ($\bar{\gamma} = 0,0019$, $t = 5,57$), alors que [Cooper et al. \(2008\)](#) documentent une relation négative, reprise comme facteur d'investissement par [Fama and French \(2015\)](#).

L'investissement en immobilisations et en stocks (`invest`) est négativement lié au rendement futur, conformément à [Chen and Zhang \(2010\)](#). Deux mesures de valorisation et de rentabilité vont également dans le sens attendu, avec des coefficients positifs pour le ratio *book-to-market* (`bm`, documenté par [Rosenberg et al. \(1985\)](#), et pour la rentabilité trimestrielle des capitaux propres chez [Hou et al. \(2015\)](#).

La volatilité de la rotation (`std_turn`) a un signe positif, quand [Chordia et al. \(2001\)](#) concluent à une relation négative entre variabilité de l'activité de négociation et rendements attendus. La variable appartenant à la même famille que `turn`, `dolvol`, `zerotrade` et `ill`.

5.3.2 Stabilité de la sélection de l'Elastic Net

Les coefficients d'un modèle pénalisé n'ont pas de loi d'échantillonnage exploitable pour un test de significativité classique. Nous mesurons donc leur fiabilité par la stabilité de sélection [Meinshausen and Bühlmann \(2010\)](#), c'est-à-dire la fréquence à laquelle chaque prédicteur conserve un coefficient non nul sur les douze fenêtres.

Trois caractéristiques seulement sont retenues dans la totalité des fenêtres : `agr`, `sp` et `indmom`. `mom12m` l'est dans 91,7 % des cas, `mom6m` et `cfp` dans 83,3 %, `std_turn` et `bm` dans 66,7 %. Aucun prédicteur n'est écarté dans toutes les fenêtres, de plus, la cohérence




FIGURE 5.3 – Fréquence de sélection des caractéristiques par l'Elastic Net sur les douze fenêtres.

de signe atteint 100 % pour l'ensemble des vingt variables les plus stables.

Le resserrement de la régularisation dont on a parlé au tableau 5.6 se voit aussi dans ces résultats. Les variables dont la fréquence de sélection vaut 25 %, soit exactement trois fenêtres, sont celles qui n'ont survécu qu'aux trois premières.

5.3.3 Importance des variables et valeurs de Shapley

Comme mentionné dans la section 4.3.5 pour LightGBM nous retenons le *gain* (la réduction totale d'erreur apportée par les découpes utilisant chaque variable) et pour la forêt aléatoire, la réduction moyenne d'impureté (la baisse de variance produite par chaque coupure, pondérée par la part de l'échantillon concernée, sommée sur les coupures de la variable puis moyennée sur les trois cents arbres). Tous deux normalisés à 100 par fenêtre puis moyennés sur les douze.

Tous les prédicteurs apparaissent dans au moins un arbre de chaque modèle. Le classement des variables les plus importantes est assez similaire entre les deux modèles avec l'exception de la variation du taux d'imposition *chtx* qui est bien classé dans LightGBM comparé au *random forest*.

Nous complétons cette sous-section par une analyse en valeurs de Shapley (Lundberg and Lee, 2017) qui apportent l'information que le gain et l'impureté ne donnent pas tels que le sens, l'homogénéité de la direction de l'effet entre titres ou si elle dépend du niveau de la caractéristique.




FIGURE 5.4 – Importance des variables agrégée sur les douze fenêtres. À gauche, le *gain* de LightGBM; à droite, la réduction moyenne d'impureté de la forêt aléatoire. Les barres d'erreur donnent l'écart-type d'une fenêtre à l'autre.




FIGURE 5.5 – Valeurs de Shapley du modèle de la dernière fenêtre, LightGBM à gauche et forêt aléatoire à droite. Chaque point est une observation de test; la couleur donne le niveau de la caractéristique et l'abscisse sa contribution à la prédiction.

Chaque point de la figure 5.5 correspond à une observation de l'échantillon de test. Sa position horizontale donne la contribution de la caractéristique à la prédiction de ce titre, et sa couleur le niveau de la caractéristique, du bleu pour les valeurs faibles au rouge pour les valeurs élevées. Un dégradé du bleu à gauche vers le rouge à droite signale donc un effet croissant, l'agencement inverse un effet décroissant, et un mélange des couleurs de part et d'autre de zéro une contribution qui dépend d'interactions plutôt que du seul niveau de la caractéristique. Les variables sont classées par amplitude moyenne des contributions.

Le tableau 5.7 croise les mesures d'importance et fait les similitudes et désaccords entre les deux familles de modèles.

TABLE 5.7 – Position de chaque caractéristique selon leurs mesures d'importance

Caractéristique	Régression linéaire	Elastic Net	LightGBM	Random Forest
	$ t $ Fama-MacBeth	Sélection (%)	Gain (%)	Importance (%)
indmom	5,53	100,0	21,58	14,30
mom12m	3,12	91,7	8,65	11,92
retvol	6,79	25,0	6,50	8,02
agr	5,57	100,0	5,60	7,92
maxret	—	41,7	3,87	6,44
mom6m	3,68	83,3	3,32	5,96
mom1m	6,40	25,0	5,56	5,83
sp	—	100,0	3,22	4,42
baspread	—	—	3,68	3,65
ep	—	25,0	—	2,88

Note. Ce tableau sert de comparatif par rapport aux dix caractéristiques les plus importantes pour la forêt aléatoire (notre meilleur modèle en termes de R^2_{oss}). Les quatre colonnes ne sont pas comparables, seuls les rangs à l'intérieur d'une colonne sont interprétables.

Les mesures de *momentum* (**indmom**, **mom12m**, **mom6m**) et la croissance de l'actif **agr** figurent en tête des quatre classements simultanément. Ce sont les signaux les plus robustes de l'étude, au sens où ils survivent à un changement complet de famille de modèles et de mesure d'importance.

Les mesures de risque et de liquidité, volatilité des rendements (**retvol**), rendement quotidien maximal (**maxret**) et fourchette achat-vente (**baspread**), pèsent lourd chez les deux modèles à arbres tout en étant peu retenues par l'Elastic Net. Les ratios de valorisation (**sp**, **ep**), eux, ne sont jamais significatifs chez Fama-MacBeth, mais sélectionnés par l'Elastic Net et présents dans le classement de la forêt.

5.4 Performance des portefeuilles

5.4.1 Rendement par décile

Suite à la construction des portefeuilles suivant la méthodologie énoncée en sous-section 4.4.1, on entame l’analyse de ce dernier via le rendement mensuel moyen réalisé par décile.




FIGURE 5.6 – Rendement mensuel moyen réalisé par décile de rendement prédit, pour les quatre modèles, sur l’ensemble de la période de test.

La figure 5.6 montre que pour les quatre modèles les rendements moyens croissent de manière assez globale du décile 1 au décile 10. Certes la monotonie n’est pas parfaite, surtout pour les déciles du centre mais si le classement d’un modèle n’avait aucune valeur, les rendements moyens seraient plats d’un décile à l’autre. On remarque que nos déciles 1 et 10 ont été bien classés et c’est là que se forme le portefeuille.

5.4.2 Mesures de performance

Les quatre portefeuilles ont un rendement moyen significativement positif avec des t -statistiques qui vont de 2,65 à 4,23, toutes au-delà du seuil usuel de 1,96. Le meilleur ratio de Sharpe est obtenu par la régression linéaire simple avec 1,22, suivie de près par LightGBM avec 1,215 et la forêt aléatoire avec 1,132, l’Elastic Net ayant des résultats moins bons à 0,766.

Le modèle le moins précis au sens du R^2_{oos} (tableau 5.5) produit le meilleur portefeuille au sens de Sharpe. La régression linéaire malgré un rendement annualisé plus faible que LightGBM et la forêt aléatoire, a le meilleur Sharpe dû à sa faible volatilité, qui se reflète aussi sur *drawdown* maximal et le pourcentage de mois positifs.




FIGURE 5.7 – Richesse cumulée en base 1 des quatre portefeuilles long-short et des deux repères long only, 2010–2021.

TABLE 5.8 – Performance des portefeuilles long-short (décile 10 – décile 1), 2010–2021

	Rend. ann.	Vol. ann.	Sharpe	Sortino	Max. DD	% mois +	t-stat
Régression linéaire	12,68	10,39	1,220	2,247	−11,34	66,0	4,23
Elastic Net	10,36	13,53	0,766	1,281	−19,75	59,0	2,65
LightGBM	15,76	12,97	1,215	2,414	−19,86	63,2	4,21
Random Forest	15,59	13,77	1,132	2,209	−20,94	63,2	3,92
<i>Repères, long only — exposition au marché non neutralisée</i>							
Univers équipondéré	11,76	17,95	0,655	1,012	−33,18	66,7	2,27
Univers pondéré capi.	13,51	14,43	0,937	1,513	−21,42	71,5	3,24

5.4.3 Constructions alternatives

La construction retenue (long-short équipondéré, décile 10 moins décile 1) n'est qu'un choix parmi d'autres. Avec les mêmes prédictions, sans aucun ré-entraînement, on teste trois constructions alternatives obtenues en croisant deux leviers : la pondération (égale ou proportionnelle à la capitalisation boursière du mois de formation) et la structure (long-short ou long only sur les 20 % des titres les mieux notés)

TABLE 5.9 – Ratio de Sharpe selon la construction du portefeuille

Modèle	Équipondéré		Pondéré capitalisation	
	Long-short	Long only 20 %	Long-short	Long only 20 %
Régression linéaire	1,220	0,819	0,829	0,938
Elastic Net	0,766	0,834	0,432	0,903
LightGBM	1,215	0,739	0,608	0,832
Random Forest	1,132	0,749	0,728	0,899
Écart moyen vs référence	—	−0,298	−0,434	−0,190

Le résultat central de ce test de robustesse est la chute du Sharpe lorsqu'on pondère par la capitalisation : $-0,434$ en moyenne.

Le passage au *long-only* engendre $-0,298$ en équipondéré et $-0,190$ en pondéré capitalisation (en moyenne) par rapport à la référence. Quoique plus faibles les modèles arrivent à dégager de la performance de la jambe longue, résultat qui peut être intéressant pour des investisseurs qui ne peuvent pas faire la vente à découvert

5.5 Portefeuille combiné

Trois règles de pondération sont testées : poids égaux, poids proportionnels au R_{oos}^2 de validation et poids de moindres carrés contraints (Granger and Ramanathan, 1984).

TABLE 5.10 – Portefeuille combiné : R_{oos}^2 et performance selon la règle de pondération

Règle de pondération	R_{oos}^2 (%)	Rend. ann.	Vol. ann.	Sharpe	Max. DD	t-stat
Poids égaux	0,491	17,69	13,31	1,329	−14,09	4,60
$\propto R^2$ de validation	0,512	17,40	13,72	1,269	−14,95	4,39
Moindres carrés	0,564	16,54	14,06	1,176	−20,63	4,07
<i>Pour mémoire, meilleurs modèles isolés</i>						
Random Forest (meilleur R^2)	0,489	15,59	13,77	1,132	−20,94	3,92
Rég. linéaire (meilleur Sharpe)	0,269	12,68	10,39	1,220	−11,34	4,23

Note. Rendements et volatilités annualisés, en %. La combinaison porte sur les quatre modèles, et le portefeuille est construit exactement comme en section 5.4.

La meilleure combinaison atteint un R^2_{oos} de 0,564 % contre 0,489 % pour la forêt aléatoire seule, soit huit points de base. La combinaison à poids égaux obtient un Sharpe de 1,329, supérieur à celui de chacun des quatre modèles pris isolément ainsi que des deux autres combinaisons.

5.6 Analyse par segment de capitalisation

On reprend ici exactement les mêmes prédictions, sans aucun ré-entraînement ni modification des modèles, et nous les ré-évaluons séparément sur trois segments de capitalisation boursière, afin de répondre à la question de savoir où les modèles fonctionnent.

TABLE 5.11 – Composition des trois groupes de capitalisation, période de test

Groupe	Entreprises moyen/mois	Part de la capi. (%)	Capi. médiane	Capi. moyenne
Small	1 550	1,0	180 M\$	195 M\$
Mid	1 550	5,1	815 M\$	949 M\$
Large	1 550	93,9	5,61 Md\$	17,57 Md\$
Univers complet	4 650	100,0	814 M\$	6,24 Md\$

On peut voir sur le tableau 5.11 que le tercile « Large » concentre 93,9 % de la capitalisation totale de l’univers contre 1,0 % pour le tercile « Small » sachant que les trois groupes comptent le même nombre de titres.

TABLE 5.12 – Performance par segment de capitalisation : trois mesures, trois lectures

Modèle	R^2_{oos} (%)			IC moyen			Sharpe long-short		
	Small	Mid	Large	Small	Mid	Large	Small	Mid	Large
Régression linéaire	0,23	0,30	0,35	0,040	0,025	0,014	1,298	0,885	0,758
Elastic Net	0,22	0,43	0,83	0,035	0,020	0,013	0,893	0,620	0,579
LightGBM	0,27	0,54	0,99	0,036	0,030	0,019	1,311	0,932	0,588
Random Forest	0,28	0,51	1,06	0,043	0,030	0,024	1,229	0,974	0,644
<i>Repères long only</i>									
Univers équilibré	—	—	—	—	—	—	0,528	0,641	0,788
Univers pondéré capi.	—	—	—	—	—	—	0,558	0,649	0,956

Note. La colonne R^2_{oos} se lit verticalement uniquement (section 4.4.2). Les comparaisons entre groupes reposent sur le IC et sur le ratio de Sharpe. Les t -statistiques du IC dépassent 1,96 dans les trois groupes pour la forêt aléatoire.

Dans le tableau 5.12 les trois mesures classent les groupes dans des ordres opposés. Le R^2_{oos} croît avec la taille comme mentionné en fin de section 4.4.2. Le IC et le Sharpe décroissent avec la taille, et ce pour les quatre modèles sans exception. Un lecteur qui s’en tiendrait au R^2 conclurait exactement l’inverse de ce que les données établissent.

Sur le segment « Large », les deux repères *long-only* obtiennent un Sharpe de 0,788 et 0,956, supérieur à celui des portefeuilles long-short des quatre modèles. Limité aux grandes capitalisations, le signal des modèles ne bat pas le simple fait de détenir le marché.

5.7 Horizon de prévision à douze mois

5.7.1 Précision et portefeuilles à douze mois

TABLE 5.13 – R_{oos}^2 agrégé, horizon douze mois (en %)

Modèle	Train	Validation	Test	Écart train – test
Régression linéaire	2,32	1,30	2,04	+0,29
Elastic Net	2,29	1,39	2,10	+0,19
LightGBM	2,52	2,19	2,17	+0,35
Random Forest	3,00	2,10	2,74	+0,26

La forêt aléatoire domine largement les trois autres modèles en termes de R_{oos}^2 . Les écarts train/ test sont tous faibles ce qui laisse penser que l’embargo joue bien son rôle.

TABLE 5.14 – Portefeuilles long-short à l’horizon douze mois, trois constructions

Modèle	Rebalancement mensuel			Cohortes chevauchantes			Rebalancement annuel		
	Rend.	Sharpe	t	Rend.	Sharpe	t	Rend.	Sharpe	t
Régression linéaire	6,41	0,425	1,47	9,34	0,740	2,55	8,59	0,446	1,54
Elastic Net	5,51	0,344	1,19	9,12	0,677	2,34	9,40	0,457	1,58
LightGBM	12,35	0,743	2,57	11,82	0,900	3,11	11,23	0,541	1,87
Random Forest	10,72	0,656	2,27	12,15	0,910	3,14	11,50	0,517	1,79

Les modèles non linéaires dominant à cet horizon pour les trois constructions. La construction en cohortes, seule à respecter l’horizon de détention de la cible, donne les meilleurs résultats avec un Sharpe de 0,910 pour la forêt aléatoire et 0,900 pour LightGBM tous deux significatifs.

5.7.2 Comparaison des deux horizons

Le R_{oos}^2 à douze mois n’est pas comparable à celui d’un mois (section 4.4.2) et les valeurs du tableau 5.13 ne se lisent qu’en comparant les modèles entre eux à horizon donné. On utilise donc encore le IC de l’équation (4.5) et le Sharpe du portefeuille long-short calculé des deux côtés avec la construction à rebalancement mensuel. Toute différence de Sharpe s’interprète donc comme un écart de qualité du signal, et non comme une conséquence du type de construction de portefeuille.

TABLE 5.15 – Horizon d’un mois contre horizon de douze mois

Modèle	IC moyen		% mois IC > 0		Sharpe		Écart
	1 mois	12 mois	1 mois	12 mois	1 mois	12 mois	
Régression linéaire	0,024	0,046	59,7	61,1	1,220	0,425	−0,795
Elastic Net	0,026	0,045	54,9	61,8	0,766	0,344	−0,422
LightGBM	0,034	0,090	63,9	74,3	1,215	0,743	−0,472
Random Forest	0,039	0,089	59,0	75,0	1,132	0,656	−0,476

Le signal à douze mois classe mieux d’après le IC, et la proportion de mois où le classement va dans le bon sens est elle aussi plus élevée dans tous les cas. Pourtant, le portefeuille qui en découle est systématiquement moins performant que celui basé sur l’approche à horizon 1 mois.

5.8 Apport des prédicteurs macroéconomiques

On a testé des configurations avec des variables macro, la première les ajoute telles quelles aux trente caractéristiques. Tous les modèles à l’exception de l’Elastic Net s’effondrent. En effet, le chiffre positif de l’Elastic Net n’a rien d’encourageant car la pénalisation annule tous les coefficients sur dix des douze fenêtres, si bien que le modèle prédit un rendement nul pour tous les titres. Les variables macroéconomiques, huit variables sur trente-huit, occupent 89 % du gain de LightGBM ainsi que de l’impureté de la forêt aléatoire.

La seconde retient les deux séries qu’un Lasso et une forêt aléatoire placent en tête, la variance du marché `macro_svar` et le ratio dividende-prix `macro_dp`, et ré-estime les quatre modèles sur trente-deux prédicteurs. Le R^2_{oos} reste négatif partout, le Sharpe de LightGBM tombe de 1,215 à 0,454, et les deux séries concentrent encore 76,6 % du gain de LightGBM et 72,2 % de l’impureté de la forêt aléatoire.

TABLE 5.16 – Effet de l’ajout des deux prédicteurs macroéconomiques retenus

Modèle	R^2_{oos} de test (%)		Sharpe	
	30 car.	+2 macro	30 car.	+2 macro
Régression linéaire	0,27	−1,36	1,220	1,220
Elastic Net	0,39	−0,93	0,766	0,786
LightGBM	0,48	−0,85	1,215	0,454
Random Forest	0,49	−1,55	1,132	0,611

Note. La colonne « 30 car. » reprend les tableaux 5.5 et 5.8. Le ratio de Sharpe est celui du portefeuille long-short équi pondéré décile 10 moins décile 1.

5.9 Alpha factoriel et coûts de mise en œuvre

5.9.1 Étude de l'Alpha

Pour l'intervalle 2010-2021 comme période d'investissement, la performance annuelle du facteur de marché est de 14,86% alors que le HML est pénalisé au global de -3,09% dont une perte de -53% au maximum, le *Small Minus Big* (SMB) est proche de zéro à 0,16%, le *momentum*, quant à lui, s'établit à 2,55 % avec un ratio de Sharpe de 0,21. Ces chiffres sont cohérents avec les constats de la décennie, marqués par la domination des grandes capitalisations de croissance au détriment d'une longue sous-performance des titres décotés (Fama and French, 2021), ainsi que par un *momentum* particulièrement exposé aux violentes rotations sectorielles de marché (Daniel and Moskowitz, 2016).

TABLE 5.17 – Alpha des portefeuilles long-short contre FF5 + *momentum*, 2010–2021

	α	$t(\alpha)$	MKT	SMB	HML	RMW	CMA	MOM	R^2	IR
Régression linéaire	10,17	4,10	0,067	0,189	0,333	0,378	0,382	0,526	0,410	1,246
Elastic Net	9,37	2,94	-0,028	0,033	0,560	0,341	0,364	0,809	0,513	0,972
LightGBM	11,74	3,60	0,081	0,119	0,325	0,866	0,512	0,469	0,394	1,138
Random Forest	13,80	4,39	-0,043	0,074	0,503	0,857	0,535	0,547	0,480	1,360
Ensemble	14,02	4,13	-0,003	0,038	0,395	0,751	0,563	0,582	0,407	1,268

α annualisé en pourcentage, t -statistiques de Newey-West à quatre retards, 144 mois. Rendements annualisés des facteurs sur la même période, MKT 14,86, SMB 0,16, HML -3,09, RMW 2,85, CMA 0,25, MOM 2,55.

Les cinq portefeuilles dégagent un alpha significatif, de 9,37 % pour l'Elastic Net à 14,02 % pour l'ensemble. Les expositions aux facteurs traditionnels n'expliquent qu'une partie des rendements observés sur la période 2010–2021. La faible rémunération de certains facteurs, ainsi que la performance négative de HML sur la période, impliquent que ces expositions ne suffisent pas à expliquer la performance des portefeuilles, ce qui laisse apparaître un alpha économiquement et statistiquement significatif. Les charges factorielles se lisent quant à elles sans surprise, avec un bêta de marché nul partout, entre -0,043 et 0,081, et un bêta de *momentum* compris entre 0,47 et 0,81 qui rejoint la place de `mom1m` et `mom12m` dans les mesures d'importance de la section 5.3. Tous les modèles chargent enfin positivement sur HML, entre 0,33 et 0,56, dans une décennie où la valeur a perdu 3 % par an.

5.9.2 Rotation et frais

La rotation mensuelle va de 1,43 à 2,66 et provient de 86 à 97 % des entrées et sorties. Les frais absorbent entre 7,1 et 12 points de rendement annuel en équipondéré, contre 3,1 à 5,1 en pondération par capitalisation, où la rotation plus élevée est compensée par un

TABLE 5.18 – Rotation, performance nette et coût de seuil, 2010–2021

	$\overline{TO}$	Rend. brut	Rend. net	Sharpe net	α net	$t(\alpha)$	$c_{1,96}^*$
<i>Équipondéré, 40 points de base</i>							
Régression linéaire	2,45	12,68	0,69	0,07	-1,76	-0,71	22,5
Elastic Net	1,43	10,36	3,27	0,24	2,43	0,77	14,6
LightGBM	2,21	15,76	4,95	0,38	1,06	0,34	31,1
Random Forest	1,85	15,59	6,49	0,47	4,82	1,56	34,7
<i>Pondéré par capitalisation, 15 points de base</i>							
Régression linéaire	2,66	9,23	4,18	0,38	1,21	0,43	8,7
Elastic Net	1,59	5,88	2,74	0,20	0,70	0,22	0,0
LightGBM	2,52	9,03	4,23	0,28	2,01	0,50	1,8
Random Forest	2,23	13,66	9,38	0,50	10,53	2,77	11,1

$\overline{TO}$ rotation mensuelle moyenne, deux jambes cumulées. Rendements et alphas annualisés en pourcentage, alphas estimés contre FF5 + *momentum*. $c_{1,96}^*$ est le coût, en points de base, qui ramène la statistique t du rendement moyen à 1,96. Coût d'emprunt de 30 points de base annuels dans tous les cas.

coût réduit. La régression linéaire illustre l'effet de façon extrême avec son ratio de Sharpe qui passe de 1,22 à 0,07.

Les statistiques t des alpha des portefeuilles équipondérés tombent toutes entre $-0,71$ et $1,56$ alors qu'elles étaient entre $2,94$ à $4,39$ en brut. Seule la forêt aléatoire en portefeuille en pondération par capitalisation conserve un alpha significatif, à $10,53$ % pour une statistique de $2,77$. Les coûts de seuil confirment ce diagnostic, la significativité du rendement moyen se perdant entre $14,6$ et $34,7$ points de base pour les portefeuilles équipondérés pour un coût retenu de 40 , et entre 0 et $11,1$ en pondération par capitalisation pour un coût retenu de 15 . Ces conclusions rejoignent celles d'[Avramov et al. \(2023\)](#), pour qui les stratégies fondées sur l'apprentissage automatique perdent l'essentiel de leur alpha dès que des contraintes de mise en œuvre réalistes leur sont imposées.

Chapitre 6

Discussion

Le chapitre précédent a présenté les résultats sans en discuter la portée. Ce chapitre revient sur ce qui les traverse, la dissociation entre les deux critères d'évaluation retenus, puis examine les trois dimensions sur lesquelles elle se manifeste, la taille des entreprises, la combinaison des modèles et l'horizon du signal.

6.1 R^2 vs Sharpe

Dans cette section on va regarder l'inversion mentionnée en section 5.4 concernant le meilleur modèle en terme de R^2 vs Sharpe. L'écart est de 0,005 pour le ratio de Sharpe entre la régression linéaire et LightGBM alors que celui du R^2 est de 0,21%. Le ratio de Sharpe étant quasi similaire, le rendement annualisé du LightGBM étant plus grand, étant donné qu'il est plus volatile, ça explique qu'il a un Sharpe similaire. On a choisi le Sharpe comme critère pour le portefeuille mais on peut se demander ce qui adviendrait de notre conclusion dans le cas où on se tournerait plutôt vers Sortino. Le ratio de Sortino déplace les classements, LightGBM y devançant la régression linéaire en première place mais la forêt aléatoire toujours derrière la régression linéaire mais cette fois ci avec un écart qui passe de 7,2% à 1,7%. La volatilité des portefeuilles issus des arbres est donc asymétrique et domine sur le côté haussier.

Le modèle linéaire est moins volatile parce que sa capacité à prédire dans rendement extrême est limitée comparée aux arbres. En effet l'attribution d'un score extrême demande qu'une action soit performante sur une grande partie des variables pour le modèle linéaire alors que les modèles d'arbres produisent ces valeurs plus rares à partir de quelques règles. C'est pourquoi la régression linéaire est plus efficace sur les grandes capitalisations, tandis que son avantage disparaît face à LightGBM sur les petites capitalisations (tableau 5.12).

Le R^2 porte sur les dix déciles, le portefeuille sur deux. 100% des prédictions sont utilisées pour le calcul du R^2 contre 20% pour le Sharpe via le classement des déciles.

Via la construction de nos modèles on cherche à maximiser le R^2 qui lui est sans égard à leur corrélation entre titres, or la volatilité du portefeuille long-short dépend de la façon dont les titres retenus co-varient. Un modèle peut donc améliorer sa précision moyenne tout en dégradant le profil de risque du portefeuille qu'il engendre.

Enfin L'équation (4.3) minimise une erreur quadratique sur le niveau alors que l'usage final ne dépend que d'un ordre ce qui peut donner des décalages entre les résultats attendus pour un certain R^2 et ce qui est réellement observé.

Un exemple frappant est la comparaison entre fenêtre glissante et fenêtre extensive de la section 5.2.1 où la forêt aléatoire obtient le même R^2_{oos} dans les deux protocoles pour un *drawdown* maximal qui passe de $-20,9\%$ à $-49,1\%$.

6.2 Taille

Un portefeuille équi pondéré place autant de capital sur une micro-capitalisation que sur les plus grandes entreprises de l'univers, la chute en Sharpe du long-short équi pondéré à ce dernier permet d'en déduire qu'une part importante de la performance des portefeuilles équi pondérés provient des titres de petite capitalisation.

De plus lors de l'analyse par taille le coefficient d'information et le ratio de Sharpe décroissent avec la capitalisation. Une stratégie qui fait investir dans les *small caps* donc dont le rendement provient d'un segment pesant 1 % de la capitalisation de l'univers limite le montant pouvant être investi sans impacter le marché. Les petites capitalisations supportent des fourchettes achat-vente plus larges et une liquidité plus faible (Amihud and Mendelson, 1986). En scénario réel les points cités précédemment éroderaient la performance du portefeuille entre un prix d'achat moyen plus élevé dû à la disponibilité des ordres de vente et aussi lorsqu'on veut vendre massivement, le prix des titres concernés chuterait

Dans le cas de notre étude, puisqu'on a déjà filtré l'univers chaque mois de son décile de capitalisation le plus faible et son décile d'illiquidité le plus élevé, on considère quand même que ce phénomène est atténué mais présent quoi qu'il arrive.

Le pouvoir prédictif documenté est statistiquement significatif, mais il se concentre sur le segment de marché où la capacité d'investissement est la plus faible

6.3 Pourquoi la moyenne simple l'emporte

Les trois règles se distinguent par le nombre de paramètres qu'elles estiment. Les poids égaux n'en estiment aucun et obtiennent le pire des R^2 et le meilleur Sharpe. La pondération par le R^2 de validation estime un scalaire par modèle et obtient la seconde place pour tous deux. Enfin les moindres carrés estiment une régression complète sous contrainte et ont le meilleur R^2 mais le pire Sharpe. Que le R^2 croisse est attendu, puisque la dernière règle optimise ce critère, cependant comme on l'a vu précédemment un grand R^2 ne s'accompagne pas obligatoirement d'un grand Sharpe.

Les moindres carrés échouent pour plusieurs raisons, notamment ils minimisent une erreur quadratique qui n'est pas celle du portefeuille. Leurs poids moyens chargent les

deux modèles à arbres à plus de quatre-vingts pour cent, d'où un profil de risque qui se rapproche de ces modèles.

L'avantage des poids égaux est que les déciles sont reformés après agrégation des prévisions, donc le décile 10 ne contient que des titres sur lesquels plusieurs modèles s'accordent. Tous les modèles ont leurs lacunes telles que la régression linéaire imposant la linéarité et les arbres prones au surapprentissage, ainsi la moyenne dissipe les erreurs propres à chacun.

6.4 Horizon du signal et fréquence de rebalancement

La comparaison menée en section 5.7 laisse de côté un point. L'écart entre les deux familles de modèles, modéré à un mois, se creuse nettement à douze, où le coefficient d'information des arbres double quand celui des modèles linéaires progresse de moitié moins. L'explication de ce phénomène doit être basée sur le fait qu'une prévision à douze mois capte des signaux de long horizon et est donc peu informative sur ce que fera le titre le mois prochain, qui est précisément ce dont portefeuille rebalancé mensuellement a besoin.

La dégradation de la performance dans les conditions d'un rebalancement mensuel provient plutôt d'un désajustement de construction que d'un défaut du signal. En alignant la détention sur l'horizon de la cible, ce que propose la construction en cohortes, on retrouve un peu plus de 50% de l'écart du ratio de Sharpe à l'horizon d'un mois. La comparaison n'est toutefois pas parfaitement propre dans la mesure où la moyenne sur douze cohortes actives, qui lisse mécaniquement la série de rendements, ne dépend pas de la qualité du classement. Le rebalancement annuel, sans ce lissage, est d'ailleurs clairement moins bon.

L'horizon de la cible relève donc de la conception du dispositif au même titre que le choix du modèle, et se fixe conjointement avec la fréquence de rebalancement. Sur les données étudiées, le signal à douze mois est le mieux classé et celui à un mois le mieux converti en portefeuille.

6.5 Pourquoi les variables macroéconomiques échouent

L'ajout des variables macroéconomiques dégrade les quatre modèles, et le mécanisme diffère selon la famille. Une variable macroéconomique prend la même valeur pour tous les titres d'un même mois. Elle ne fait que déplacer la constante du modèle linéaire d'un mois à l'autre sans modifier le classement des titres donc lors de la construction des portefeuilles les déciles sont donc identiques. Les coefficients des 30 caractéristiques restent tels quels. Cependant, via l'ajout des coefficients macroéconomiques, le R_{oos}^2 évolue alors que le Sharpe reste inchangé (tableau 5.16).

Pour les modèles arborescents, une variable constante en coupe transversale mais variable dans le temps offre des points de coupure qui séparent parfaitement des périodes entières ce qui fait que la réduction d'erreur associée est élevée sur l'échantillon d'entraînement. Le bloc macroéconomique capte ainsi la majeure partie de l'importance tout en n'apportant aucune information sur le classement des titres. L'arbre mémorise le calendrier passé au lieu d'apprendre un signal, provoquant l'effondrement du R^2 hors échantillon et du ratio de Sharpe pour LightGBM et la forêt aléatoire.

Chapitre 7

Conclusion

Ce mémoire a confronté quatre modèles de prévision du rendement excédentaire mensuel sur un panel d'actions américaines, évalués par douze fenêtres glissantes couvrant les années 2010 à 2021.

Les quatre modèles produisent un R^2 de test positif et les deux modèles à arbres devancent les deux modèles linéaires, pour un gain d'une vingtaine de points de base obtenu au prix d'un temps d'estimation qui passe de la minute à près de cinq heures. Les mesures de *momentum* et la croissance de l'actif figurent en tête des quatre mesures d'importance simultanément, quand l'ajout des prédicteurs macroéconomiques agrégés dégrade au contraire les quatre modèles.

Les quatre portefeuilles long-short dégagent un rendement moyen significatif et la combinaison à poids égaux fait mieux que chacun des modèles isolés, mais cette performance dépend de choix qui ne touchent pas au modèle. La pondération par la capitalisation coûte plus de quatre dixièmes de ratio de Sharpe, la suppression de la jambe vendeuse trois dixièmes. Le pouvoir prédictif décroît par ailleurs avec la capitalisation, au point qu'aucun portefeuille ne bat la détention passive sur le seul segment des grandes capitalisations. Il se concentre donc là où la capacité d'investissement est la plus faible.

Les portefeuilles dégagent tous un rendement excédentaire significatif, montrant que leur surperformance dépasse les simples expositions aux facteurs de risque traditionnels et résiste au repli marqué tel que "valeur" sur la période. Nets de frais de transaction et de coût d'emprunt, les statistiques de Student tombent d'un intervalle compris entre 2,94 et 4,39 à un intervalle compris entre $-0,71$ et $1,56$, et un seul des huit conserve un alpha significatif. Les coûts de seuil se situent à des niveaux que les frais réellement supportés atteignent sans difficulté sur ce segment de marché.

L'apport de ce travail tient moins à un modèle qu'à la façon de l'évaluer. Mesurer chaque résultat par le R^2 hors échantillon et par le portefeuille montre que ces deux critères ne classent pas les modèles dans le même ordre, et le constat se reproduit d'un modèle à l'autre, d'une règle de combinaison à l'autre, d'un segment de capitalisation à l'autre et d'un protocole de fenêtre à l'autre. La réserve porte sur la force de l'écart plus que sur son existence, puisque le classement s'inverse lorsque le ratio de Sortino remplace le ratio de Sharpe. Ce qui est établi n'est donc pas qu'un modèle linéaire domine, mais que les deux critères se dissocient.

Plusieurs limites appellent des prolongements. Les réseaux de neurones ont été écartés pour des raisons de temps de calcul alors qu'ils sont les mieux placés pour capter les

interactions entre caractéristiques. La perte quadratique pourrait être remplacée par un objectif aligné sur l'usage final, perte de classement ou ratio de Sharpe net de frais. Aucun test formel n'a été mené sur les différences de précision entre modèles, alors qu'elles fondent une partie des classements présentés. Enfin les frais sont modélisés forfaitairement, sans impact de marché ni fourchette propre à chaque titre, ce qui pèse d'autant plus que la performance se concentre sur les petites capitalisations.

Bibliographie

- Y. Amihud. Illiquidity and stock returns : Cross-section and time-series effects, 2002. *Journal of Financial Markets*, 5(1), 31–56.
- Y. Amihud and H. Mendelson. Asset pricing and the bid-ask spread. *Journal of Financial Economics*, 17(2) :223–249, 1986.
- A. Ang, R. J. Hodrick, Y. Xing, and X. Zhang. The cross-section of volatility and expected returns, 2006. *Journal of Finance*, 61(1), 259–299.
- D. Avramov, S. Cheng, and L. Metzker. Machine learning vs. economic restrictions : Evidence from stock return predictability, 2023. *Management Science*, 69(5), 2587–2619.
- J. M. Bates and C. W. J. Granger. The combination of forecasts, 1969. *Operational Research Quarterly*, 20(4), 451–468.
- C. Bergmeir and J. M. Benítez. On the use of cross-validation for time series predictor evaluation, 2012. *Information Sciences*, 191, 192–213.
- J. Boudoukh, M. Richardson, and R. F. Whitelaw. The myth of long-horizon predictability, 2008. *Review of Financial Studies*, 21(4), 1577–1605.
- L. Breiman. Bagging predictors, 1996. *Machine Learning*, 24(2), 123–140.
- L. Breiman. Random forests, 2001. *Machine Learning*, 45(1), 5–32.
- L. Breiman, J. H. Friedman, R. A. Olshen, and C. J. Stone. Classification and regression trees, 1984. Wadsworth, Belmont, CA.
- J. Y. Campbell and S. B. Thompson. Predicting excess stock returns out of sample : Can anything beat the historical average?, 2008. *Review of Financial Studies*, 21(4), 1509–1531.
- M. M. Carhart. On persistence in mutual fund performance, 1997. *Journal of Finance*, 52(1), 57–82.
- L. Chen and L. Zhang. A better three-factor model that explains more anomalies, 2010. *The Journal of Finance*, 65(2), 563–595.
- N.-F. Chen, R. Roll, and S. A. Ross. Economic forces and the stock market. *The Journal of Business*, 59(3) :383–403, 1986.

- T. Chen and C. Guestrin. Xgboost : A scalable tree boosting system, 2016. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794.
- T. Chordia, A. Subrahmanyam, and V. R. Anshuman. Trading activity and expected stock returns, 2001. *Journal of Financial Economics*, 59(1), 3–32.
- D. Chun, J. Kang, and J. Kim. Forecasting returns with machine learning and optimizing global portfolios : Evidence from the Korean and U.S. stock markets. *Financial Innovation*, 10(1) :124, 2024. doi : 10.1186/s40854-024-00648-w.
- J. H. Cochrane. Presidential address : Discount rates. *Journal of Finance*, 66(4) :1047–1108, 2011.
- M. J. Cooper, H. Gulen, and M. J. Schill. Asset growth and the cross-section of stock returns, 2008. *Journal of Finance*, 63(4), 1609–1651.
- K. Daniel and T. J. Moskowitz. Momentum crashes, 2016. *Journal of Financial Economics*, 122(2), 221–247.
- V. T. Datar, N. Y. Naik, and R. Radcliffe. Liquidity and stock returns : An alternative test, 1998. *Journal of Financial Markets*, 1(2), 203–219.
- V. DeMiguel, L. Garlappi, and R. Uppal. Optimal versus naive diversification : How inefficient is the $1/n$ portfolio strategy?, 2009. *Review of Financial Studies*, 22(5), 1915–1953.
- E. F. Fama and K. R. French. Common risk factors in the returns on stocks and bonds, 1993. *Journal of Financial Economics*, 33(1), 3–56.
- E. F. Fama and K. R. French. A five-factor asset pricing model. *Journal of Financial Economics*, 116(1) :1–22, 2015.
- E. F. Fama and K. R. French. The value premium, 2021. *The Review of Asset Pricing Studies*, 11(1), 105–121.
- E. F. Fama and J. D. MacBeth. Risk, return, and equilibrium : Empirical tests, 1973. *Journal of Political Economy*, 81(3), 607–636.
- C. Fieberg, D. Metko, T. Poddig, and T. Loy. Machine learning techniques for cross-sectional equity returns’ prediction. *OR Spectrum*, 45(1) :289–323, 2023. doi : 10.1007/s00291-022-00693-w.
- J. Freyberger, A. Neuhierl, and M. Weber. Dissecting characteristics nonparametrically, 2020. *Review of Financial Studies*, 33(5), 2326–2377.

- J. Friedman, T. Hastie, and R. Tibshirani. Regularization paths for generalized linear models via coordinate descent, 2010. *Journal of Statistical Software*, 33(1), 1–22.
- J. H. Friedman. Greedy function approximation : A gradient boosting machine, 2001. *Annals of Statistics*, 29(5), 1189–1232.
- J. Grammig, C. Hanenbergh, C. Schlag, and J. Sönksen. Diverging roads : Theory-based vs. machine learning-implied stock risk premia. *Journal of Financial Econometrics*, 23(2) :nbaf005, 2025. doi : 10.1093/jjfinec/nbaf005.
- C. W. J. Granger and R. Ramanathan. Improved methods of combining forecasts, 1984. *Journal of Forecasting*, 3(2), 197–204.
- J. Green, J. R. M. Hand, and X. F. Zhang. The characteristics that provide independent information about average U.S. monthly stock returns. *The Review of Financial Studies*, 30(12) :4389–4436, 2017.
- S. Gu, B. Kelly, and D. Xiu. Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5) :2223–2273, 2020.
- L. P. Hansen and R. J. Hodrick. Forward exchange rates as optimal predictors of future spot rates : An econometric analysis, 1980. *Journal of Political Economy*, 88(5), 829–853.
- C. R. Harvey, Y. Liu, and H. Zhu. ... and the cross-section of expected returns, 2016. *Review of Financial Studies*, 29(1), 5–68.
- T. Hastie, R. Tibshirani, and J. Friedman. The elements of statistical learning : Data mining, inference, and prediction, 2009. 2^e édition, Springer, New York.
- A. E. Hoerl and R. W. Kennard. Ridge regression : Biased estimation for nonorthogonal problems, 1970. *Technometrics*, 12(1), 55–67.
- K. Hornik, M. Stinchcombe, and H. White. Multilayer feedforward networks are universal approximators, 1989. *Neural Networks*, 2(5), 359–366.
- K. Hou, C. Xue, and L. Zhang. Digesting anomalies : An investment approach, 2015. *The Review of Financial Studies*, 28(3), 650–705.
- K. Hou, C. Xue, and L. Zhang. Replicating anomalies, 2020. *Review of Financial Studies*, 33(5), 2019–2133.
- N. Jegadeesh. Evidence of predictable behavior of security returns, 1990. *Journal of Finance*, 45(3), 881–898.

- N. Jegadeesh and S. Titman. Returns to buying winners and selling losers : Implications for stock market efficiency, 1993. *Journal of Finance*, 48(1), 65–91.
- M. C. Jensen. The performance of mutual funds in the period 1945–1964, 1968. *Journal of Finance*, 23(2), 389–416.
- G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu. LightGBM : A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, pages 3146–3154, 2017.
- A. S. Kurucan and A. Hepşen. Machine learning for cross-sectional return predictability : Evidence from global stock markets. *Doğuş Üniversitesi Dergisi*, 26(1) :315–338, 2025. doi : 10.31671/doujournal.1534375.
- E. Leung, H. Lohre, D. Mischlich, Y. Shea, and M. Stroh. The promises and pitfalls of machine learning for predicting stock returns, 2021. *Journal of Financial Data Science*, 3(2), 21–50.
- W. Liu. A liquidity-augmented capital asset pricing model, 2006. *Journal of Financial Economics*, 82(3), 631–671.
- M. López de Prado. *Advances in financial machine learning*, 2018. John Wiley & Sons, Hoboken, NJ.
- S. M. Lundberg and S.-I. Lee. A unified approach to interpreting model predictions, 2017. In *Advances in Neural Information Processing Systems*, 30.
- S. M. Lundberg, G. Erion, H. Chen, A. DeGrave, J. M. Prutkin, B. Nair, R. Katz, J. Himmelfarb, N. Bansal, and S.-I. Lee. From local explanations to global understanding with explainable ai for trees, 2020. *Nature Machine Intelligence*, 2(1), 56–67.
- N. Meinshausen and P. Bühlmann. Stability selection, 2010. *Journal of the Royal Statistical Society : Series B*, 72(4), 417–473.
- E. Mekelburg and J. Strauss. Pooling and winsorizing machine learning forecasts to predict stock returns with high-dimensional data, 2024. *Journal of Empirical Finance*, 79, 101538.
- T. J. Moskowitz and M. Grinblatt. Do industries explain momentum ?, 1999. *Journal of Finance*, 54(4), 1249–1290.
- W. K. Newey and K. D. West. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix, 1987. *Econometrica*, 55(3), 703–708.

- W. K. Newey and K. D. West. Automatic lag selection in covariance matrix estimation, 1994. *Review of Economic Studies*, 61(4), 631–653.
- R. Novy-Marx. The other side of value : The gross profitability premium, 2013. *Journal of Financial Economics*, 108(1), 1–28.
- R. Novy-Marx and M. Velikov. A taxonomy of anomalies and their trading costs, 2016. *Review of Financial Studies*, 29(1), 104–147.
- M. A. Petersen. Estimating standard errors in finance panel data sets : Comparing approaches, 2009. *Review of Financial Studies*, 22(1), 435–480.
- M. Pinelis and D. Ruppert. Maximizing portfolio predictability with machine learning, 2023. *SSRN Working Paper*.
- D. E. Rapach, J. K. Strauss, and G. Zhou. Out-of-sample equity premium prediction : Combination forecasts and links to the real economy, 2010. *Review of Financial Studies*, 23(2), 821–862.
- B. Rosenberg, K. Reid, and R. Lanstein. Persuasive evidence of market inefficiency, 1985. *The Journal of Portfolio Management*, 11(3), 9–16.
- L. S. Shapley. A value for n-person games, 1953. Dans *Contributions to the Theory of Games*, vol. II, Annals of Mathematics Studies 28, Princeton University Press, 307–317.
- W. F. Sharpe. Capital asset prices : A theory of market equilibrium under conditions of risk, 1964. *Journal of Finance*, 19(3), 425–442.
- R. G. Sloan. Do stock prices fully reflect information in accruals and cash flows about future earnings ?, 1996. *The Accounting Review*, 71(3), 289–315.
- J. Smith and K. F. Wallis. A simple explanation of the forecast combination puzzle, 2009. *Oxford Bulletin of Economics and Statistics*, 71(3), 331–355.
- F. A. Sortino and L. N. Price. Performance measurement in a downside risk framework, 1994. *Journal of Investing*, 3(3), 59–64.
- C. Spearman. The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1) :72–101, 1904.
- C. Strobl, A.-L. Boulesteix, A. Zeileis, and T. Hothorn. Bias in random forest variable importance measures : Illustrations, sources and a solution, 2007. *BMC Bioinformatics*, 8, article 25.
- R. Tibshirani. Regression shrinkage and selection via the lasso, 1996. *Journal of the Royal Statistical Society, Series B*, 58(1), 267–288.

- I. Welch and A. Goyal. A comprehensive look at the empirical performance of equity premium prediction, 2008. *Review of Financial Studies*, 21(4), 1455–1508.
- D. Wolff and U. Neugebauer. Tree-based machine learning approaches for equity market predictions, 2019. *Journal of Asset Management*, 20(4), 273–288.
- H. Zou and T. Hastie. Regularization and variable selection via the elastic net, 2005. *Journal of the Royal Statistical Society, Series B*, 67(2), 301–320.

Annexe A

Annexes

A.1 Caractéristiques et prédicteurs de l'univers candidat

Le tableau A.1 donne la liste des caractéristiques candidates avec leur définition.

TABLE A.1: Caractéristiques d'entreprise de l'univers candidat. Définitions et références d'origine de chaque signal reprises de [Gu et al. \(2020\)](#).

Code	Définition
mom1m	Rendement du mois précédent, associé à la réversion de court terme (Jegadeesh, 1990)
mom6m	Rendement cumulé sur les six mois précédents (Jegadeesh et Titman, 1993)
mom12m	Rendement cumulé sur les douze mois précédents (Jegadeesh et Titman, 1993)
chmom	Variation du momentum à six mois (Gettleman et Marks, 2006)
indmom	Momentum du secteur d'appartenance (Moskowitz et Grinblatt, 1999)
maxret	Rendement quotidien le plus élevé du mois (Bali, Cakici et Whitelaw, 2011)
mvel1	Capitalisation boursière (Banz, 1981)
dolvol	Volume échangé en dollars (Chordia, Subrahmanyam et Anshuman, 2001)
turn	Rotation du flottant (Datar, Naik et Radcliffe, 1998)
std_turn	Volatilité de la rotation (Chordia, Subrahmanyam et Anshuman, 2001)
ill	Mesure d'illiquidité (Amihud, 2002)
zerotrade	Nombre de jours sans transaction (Liu, 2006)
baspread	Fourchette entre cours acheteur et cours vendeur (Amihud et Mendelson, 1989)
retvol	Volatilité des rendements quotidiens du mois (Ang, Hodrick, Xing et Zhang, 2006)
idiovol	Volatilité idiosyncratique (Ali, Hwang et Trombley, 2003)

suite page suivante

Tableau A.1 (suite)

Code	Définition
beta	Bêta de marché (Fama et MacBeth, 1973)
bm	Valeur comptable rapportée à la valeur de marché (Rosenberg, Reid et Lanstein, 1985)
ep	Bénéfices rapportés au prix (Basu, 1977)
sp	Chiffre d'affaires rapporté au prix (Barbee, Mukherji et Raines, 1996)
cfp	Flux de trésorerie rapportés au prix (Desai, Rajgopal et Venkatachalam, 2004)
agr	Croissance de l'actif total (Cooper, Gulen et Schill, 2008)
chcsho	Variation du nombre d'actions en circulation (Pontiff et Woodgate, 2008)
egr	Croissance des capitaux propres (Richardson, Sloan, Soliman et Tuna, 2005)
invest	Investissement en immobilisations et en stocks (Chen et Zhang, 2010)
gma	Rentabilité brute rapportée à l'actif (Novy-Marx, 2013)
operprof	Rentabilité opérationnelle (Fama et French, 2015)
roaq	Rentabilité de l'actif, données trimestrielles (Balakrishnan, Bartov et Faurel, 2010)
roeq	Rentabilité des capitaux propres, données trimestrielles (Hou, Xue et Zhang, 2015)
acc	Accruals comptables (Sloan, 1996)
chtx	Variation de la charge d'impôt (Thomas et Zhang, 2011)

Source : Gu et al. (2020).

A.2 Prédicteurs macroéconomiques

TABLE A.2: Description des variables financières et macroéconomiques brutes.

Variable	Description
Index	Niveau de l'indice boursier S&P 500
D12	Dividendes du S&P 500 cumulés sur les douze derniers mois
E12	Bénéfices du S&P 500 cumulés sur les douze derniers mois
b/m	Ratio valeur comptable rapportée à la valeur de marché
tbl	Taux des bons du Trésor américain à trois mois
AAA	Rendement des obligations d'entreprises notées AAA

Tableau A.2 (suite)

Variable	Description
BAA	Rendement des obligations d'entreprises notées BAA
lty	Rendement des obligations d'État américaines à long terme
ntis	Émissions nettes d'actions rapportées à la capitalisation boursière
Rfree	Taux de rendement sans risque
infl	Taux d'inflation fondé sur l'indice des prix à la consommation
ltr	Rendement des obligations d'État à long terme
corpr	Rendement des obligations d'entreprises à long terme
svar	Variance du marché, calculée à partir des rendements journaliers
csp	Prime bêta transversale
CRSP_SPvw	Rendement pondéré par la valeur du S&P 500, dividendes inclus
CRSP_SPvwx	Rendement pondéré par la valeur du S&P 500, hors dividendes

Source : Welch and Goyal (2008).

Les huit prédicteurs sont construits à partir des variables présentées dans le Tableau A.2, toutes issues de la base de données de Welch and Goyal (2008) :

$$\begin{aligned}
 dp_t &= \log D12_t - \log \text{Index}_t, & ep_t &= \log E12_t - \log \text{Index}_t, \\
 bm_t &= (B/M)_t, & ntis_t &= ntis_t, \\
 tbl_t &= r_t^{3m}, & tms_t &= r_t^{\text{LT}} - r_t^{3m}, \\
 dfy_t &= y_t^{\text{Baa}} - y_t^{\text{Aaa}}, & svar_t &= \sum_{d \in t} r_d^2.
 \end{aligned} \tag{A.1}$$

Le ratio dividendes-prix dp et le ratio bénéfices-prix ep rapportent les dividendes et les bénéfices au niveau du marché et constituent ainsi des indicateurs de valorisation agrégée. Le ratio bm complète ces mesures en rapportant la valeur comptable à la valeur de marché. La variable $ntis$ mesure les émissions nettes d'actions des sociétés cotées au NYSE relativement à leur capitalisation boursière. Le taux des bons du Trésor à trois mois tbl représente le niveau des taux courts, tandis que l'écart de terme tms correspond à la différence entre le taux obligataire de long terme et le taux court. L'écart de défaut dfy mesure la différence entre les rendements des obligations d'entreprises notées Baa et Aaa et reflète ainsi les conditions de risque de crédit. Enfin, $svar$ correspond à la somme des carrés des rendements quotidiens du marché au cours du mois et fournit une mesure de la volatilité réalisée.

Le fichier fournit également le taux sans risque mensuel R_t^f , qui ne sert pas de prédicteur mais entre dans la définition de la variable expliquée (section 3.3.3).

A.3 Significativité des caractéristiques par Fama-MacBeth

TABLE A.3 – Caractéristiques significatives à 5 %, régressions de Fama-MacBeth

Caractéristique	Coef. moyen	Écart-type NW	<i>t</i> -stat NW	% mois signe +
turn	−0,00914	0,00104	−8,79	27,0
std_turn	+0,00542	0,00069	+7,86	65,8
retvol	−0,00675	0,00099	−6,79	37,8
mom1m	−0,00557	0,00087	−6,40	36,2
zerotrade	−0,00570	0,00097	−5,89	37,8
agr	+0,00191	0,00034	+5,57	61,6
indmom	+0,00346	0,00063	+5,53	63,4
gma	+0,00254	0,00056	+4,55	60,2
mom6m	+0,00299	0,00081	+3,68	61,0
dolvol	−0,00573	0,00165	−3,48	39,6
ill	−0,00530	0,00169	−3,13	43,7
mom12m	+0,00309	0,00099	+3,12	60,6
invest	−0,00108	0,00039	−2,80	43,1
bm	+0,00123	0,00047	+2,63	57,1
roeq	+0,00093	0,00045	+2,09	52,3